

生成式人工智能与内容平台的动态治理：从普惠式扩量到选择性扶持

朱千子 朱胜豪

对外经济贸易大学经济学院

2026 年 9 月 2 日

摘要

本文研究生成式人工智能降低数字内容生产成本后，内容平台为何会从普惠式项目扶持转向选择性准入与绩效激励，并以 AI 短剧为主要应用场景。模型包含平台、异质创作者和稀缺的用户注意力。每一期，平台先公布固定支付与收入分成，创作者据此决定进入并选择不可合同化的质量努力，平台观察内容后配置推荐曝光。项目增加扩大了题材和团队的试验范围，也加剧了注意力拥堵、筛选成本和创作者激励稀释。

分析从终端期的曝光、努力和进入均衡出发，依次求解 $t \in \{1, 2\}$ 的两期模型与离散时间无限期 Bellman 方程。创作资本和推荐资本在批次间积累；快速变化的热点则由两种替代性在线学习规格刻画：高斯漂移状态下的内生测试曝光，以及两题材马尔可夫热点切换下的探索—利用配置。项目进入的动态边际价值由当期边际利润、创作资本积累价值与推荐学习价值构成。它在零补贴自然进入规模处的符号，决定平台扩大补贴、维持零补贴或采用选择性准入。

当推荐资本逐步成熟、数据学习的边际价值下降而自然进入规模上升时，模型产生内生的技术成熟阈值。阈值以上，统一非负补贴无法实施平台的目标进入规模，政策转向资格审核、项目申请制和定向扶持。数值部分在同一组期内均衡原语下，以向后归纳求解两期均衡，以值函数迭代求解无限期平稳马尔可夫均衡。公开短视频数据约束类别多样性，其余参数采用透明的部分校准，并接受参数与网格敏感性检验。数值均衡得到早期正支持、成熟期零支付配额的转换；转换是否出现，取决于学习收益相对当期匹配收益的下降速度。

在线学习结果显示，新增项目和测试曝光共同决定反馈精度。热点持续漂移时，平台无法永久消除需求不确定性，测试政策随后验均值、精度和状态持久性调整。热点切换既增加刷新信息的需要，也缩短信号的有效期限，所以更快切换未必带来更多探索。成熟政策由此可能表现为状态依赖的循环调整，而非一次性的单向转换。

关键词：生成式人工智能；内容平台；平台治理；注意力拥堵；动态合同；推荐资本；在线学习；马尔可夫热点

1 引言

生成式人工智能正在改变数字内容市场的稀缺性。剧本、图像、声音和视频片段的生成成本下降后，市场约束逐渐从“谁能生产”移向“哪些内容能被发现、精修并获得注意力”。任务方法的宏观研究把人工智能的经济作用落在具体任务的成本节约和互补性改善上，模型能力本身不足以推断总体价值 [1]。企业场景的微观证据显示，生成式人工智能提高了平均生产率，经验较少的劳动者获益更多，但效果随任务和技能而异 [7]。创意写作实验还发现，人工智能建议提高单个作品的平均评价，同时增加作品之间的相似性 [10]。本文据此研究 AI 短剧市场中的均衡效应：生产成本下降可以同时带来进入扩张、质量改善和内容同质化，平台价值则取决于供给如何占用注意力并产生学习收益。

本文把“生成式内容平台”定义为同时具备异质创作者进入、算法化分发、有限用户注意力以及补贴或收入分成工具的平台。AI 短剧集中体现了这一制度结构：剧本、分镜、角色、配音和后期等任务被生成式人工智能重组，内容能否触达用户又高度依赖冷启动测试与后续推荐。相同机制也适用于 AI 漫剧、数字人视频和其他 AI 辅助视听内容。本文聚焦平台分发与治理，基础模型竞争、全经济就业替代以及脱离推荐分发的一般创意产业留在分析边界之外。

内容平台具有典型的多边结构：平台连接创作者、用户以及可能存在的广告主，并通过合同和治理规则影响各侧参与及其交互 [17, 24]。创作者经济研究表明，收入分成、创作者支持工具和平台基础设施会共同改变内容供给、进入构成和生态集中度 [5]。平台的作用也不限于定价；准入、质量标准、信息披露、搜索与推荐都是非价格治理工具 [26]。尤其是，推荐规则会反过来改变创作者的质量投入和平台的收入分成选择 [23]。因此，固定支付、收入分成、准入与推荐曝光不能被视为彼此独立的政策模块。

供给扩张还受到两类约束。第一，用户时间、测试流量、审核能力和重点运营资源具有稀缺性。媒体经济学中的拥堵分析表明，更多媒体或更多商业信息未必单调改善用户体验，因为平台对有限注意力的使用会产生拥堵外部性 [2]；推荐系统既可能帮助用户发现长尾内容，也可能通过反馈和流行度偏差改变总体内容多样性 [14]。第二，项目数据具有跨项目学习价值。数据驱动学习的动态模型表明，企业竞争优势取决于学习曲线的形状、已有数据积累以及剩余学习空间 [18]；社会数据研究进一步说明，一个主体的数据可能帮助预测其他主体，从而使单条新增数据的价值取决于既有样本与相关结构 [3]。映射到内容平台，早期项目不仅创造当期播放，还帮助平台识别题材、受众与创作者；但随着推荐资本成熟，新增相似项目提供的信息可能出现边际递减。

近期动态数据经济学提供了把上述机制写成递归学习问题的方法。交易生成的信号可以通过后验精度压缩为可递归的数据状态，无须把完整历史放入状态空间 [12]；一般马尔可夫决策问题则允许行动通过转移概率影响下一期状态与价值 [11]。更早的变化环境试验模型已经表明，需求切换既提高追踪当前状态的必要性，也缩短一条新信息的有效寿命，因而可能出现高试验、良好追踪与低试验、局部锁定两种区制 [20]。推荐系统理论则把推荐本身视为信息生产工具：平台可以牺牲部分当期匹配来诱导用户试验 [9]，前瞻型推荐算法据此在探索与利用之间进行动态权衡 [8]；近期价格—推荐联合模型也令反馈到达率随交易量增加 [27]。本文从这些研究中提取“行动改变信号精度和后验转移”的共同结构，并把它嵌入包含进入、拥堵与平台合同的环境。平台目标仍是折现利润最大化；在线优化文献中的变化预算和动态遗憾用于理解非平稳性的代价 [4]，但不进入本文目标函数。渐进行动学习区分了当期行动持续产生公共信息与等待期权 [21]。本文以经营批次为单位，因此保留连续信息生成，省略不可逆采用和多年等待。

多模态推荐技术为上述区分提供了工程背景。WeMM-Embedding 是微信视觉团队发布的多模态表征模型，将文本、图像、视频和交错多模态输入映射到统一表示空间，并报告其已用于视频号、公众号和微信搜索等场景中的候选召回、排序特征、用户序列建模与跨域内容理解 [29]。公开材料覆盖多模态表征模型、模型权重及相关推理和评测代码，未披露视频号完整的候选生成、商业目标权重和最终流量分配规则。本文据此刻画推荐资本对内容识别和用户匹配效率的作用；结构参数与因果效应仍由本文模型和未来经验设计决定。

本文关注的问题是：当生成式人工智能持续降低内容生产成本时，平台应当如何在项目进入、创作者质量努力、推荐曝光和跨期学习之间设计动态激励？为何产业早

期扩大试验范围的普惠式扶持，会在推荐能力和自然供给成熟以后转向资格审核、项目申请制和定向扶持？

模型采用离散时间。每一期对应一个完整的经营批次，依次包含合同公布、项目进入、内容生产、推荐测试、收益结算和数据回流。平台在批次之间更新创作者生态知识和推荐能力，这一设定也符合推荐系统依据用户反馈序贯调整选择规则的描述 [22]。WeMM-Embedding 的“第一阶段大规模多模态对齐、第二阶段精选数据精炼”属于机器学习训练流程；本文的 $t = 1, 2$ 表示两个经济经营批次。

本文有四点贡献。第一，模型区分任务层面的生成式人工智能冲击与平台层面的均衡价值。外生技术水平 τ 降低项目固定成本并改善基础生产能力；项目价值还取决于人工质量努力、推荐曝光和注意力拥堵。这一机制连接了人工智能生产率研究与平台治理，也解释了为何创作成本下降不必对应永久扩张的内容供给。

第二，本文在统一框架中刻画固定支付、收入分成、事后曝光与选择性准入，并把合同问题表述为目标进入规模的实施问题。固定支付扩大进入的外延边际，收入分成提高创作者努力回报却降低平台保留收益，事后曝光则受到注意力拥堵约束。在此基础上，本文定义项目进入的动态边际价值，并将其分解为当期利润、创作资本和推荐学习三个部分。同一个边际条件同时决定补贴与准入。

第三，本文区分创作资本 K_t 与推荐资本 M_t ，先求解 $t \in \{1, 2\}$ 的两期模型，再推广到 $t = 0, 1, 2, \dots$ 的无限期环境。前者提高基础内容质量并降低制作成本，后者提高多模态识别和用户匹配效率，并改变项目之间的有效拥堵。本文从边际进入价值递减、学习回报递减和自然进入增加三个原始条件出发，给出推荐资本的内生成熟阈值：阈值以下实施正补贴，阈值处补贴为零，阈值以上统一非负支付无法实施平台目标，因而需要选择性准入。若匹配改善带来的当期收益足够强，单交叉条件可能失败，阶段转换也不会出现。这一条件使模型结论可以接受经验检验。

第四，在线学习扩展把慢速积累的推荐资本与快速变化的热点状态分开。高斯规格由项目进入与测试曝光共同决定信号精度；热点规格令两类题材按照马尔可夫链切换，并由平台选择类别曝光。两种规格都把完整反馈历史压缩为后验状态。非平稳需求使平台在结构资本成熟后仍可能反复进入测试区。

下文先建立期内行动顺序并求解终端期均衡，再讨论合同如何实施目标进入规模。两期与无限期模型给出动态边际进入楔子和政策阶段转换；在线学习部分加入高斯漂移状态与马尔可夫热点。数值部分随后报告两期、无限期与信念状态均衡、稳健性检验和经验预测。

2 理论模型：项目进入、注意力拥堵与平台动态激励

2.1 模型目的与研究问题

本文解释生成式内容平台的激励政策为何具有阶段性。产业形成初期，平台通过固定投资、收入保底、收入分成和推荐流量吸引项目；生成式人工智能降低制作成本、扩大项目供给后，平台逐步减少普遍性固定支持，转而依靠绩效分成、准入控制和项目筛选调节供给。

创作者经济研究通常把平台、创作者和用户放在同一框架中。平台用合同影响内容生产，再用推荐政策把内容配置给用户。收益型合同按照实现收益的一定比例向创作者支付，真实质量努力却难以事前写入合同，这与可观察绩效下的经典道德风险逻辑一致 [19]。合同与推荐因此需要联合求解：平台先公布合同，创作者生产内容，平台观察内容后决定推荐。推荐规则既决定当期曝光，也改变质量投入的预期回报；算法若不能及时识别高质量内容，创作者会因未来推荐收益折现而减少当前投入。

模型包含两组相互关联的权衡。第一组来自试验广度与注意力拥堵。更多项目提高平台发现高潜力题材、制作团队和爆款作品的概率，用户注意力、测试流量、人工审核和重点运营能力却无法同比扩张。项目增加会压低单个项目的预期曝光、收益和质量投入，并抬高筛选与合规成本。

第二组来自创作者质量激励与平台流量激励。提高收入分成会增加创作者改善质量的边际私人回报，也会减少平台从每单位有效播放中保留的收益。分成过低时，创作者投入不足；分成过高时，平台在内容形成后缺少继续投放流量的动力。固定投资因而主要影响进入的外延边际，收入分成影响质量努力的集约边际，推荐曝光直接决定当期商业绩效。

模型先在两期离散时间内求解项目进入、质量努力和平台曝光，再把平台合同推广到无限期。平台进行跨期动态优化，每一期进入的创作者项目作当期最优反应。长期创作者的动态选择留作扩展。

后文统一使用“项目”和“作品”，主要制度解释仍是 AI 短剧。模型适用于满足三个条件的生成式内容场景：平台影响内容发现与曝光；创作者面对可比较的固定支持或收入分成；项目上线后的行为数据会更新内容与用户的匹配认知。完全去中心化分发、平台事前完全承诺流量或项目之间没有学习外部性的市场，需要相应调整曝光承诺、推荐资本或动态阈值。

2.2 基本环境

2.2.1 时间、主体与潜在项目集合

基准模型包含两个时期：

$$t \in \{1, 2\}.$$

经济中存在一个长期经营的内容分发平台；AI 短剧应用中可将其理解为短视频平台。每一期存在一个总测度为 $\bar{N} > 0$ 的潜在生成式内容项目连续统：

$$\mathcal{I}_t = [0, \bar{N}].$$

潜在项目可以理解为有能力在第 t 期制作和提交 AI 短剧、AI 漫剧、数字人视频或其他 AI 辅助视听内容的创作者与制作团队。本文将潜在项目池的总测度 $\bar{N}$ 设为外生且不随时间变化。

令

$$\mathcal{E}_t \subseteq \mathcal{I}_t$$

表示第 t 期实际进入的项目集合，并定义：

$$n_t = \mu(\mathcal{E}_t) \in [0, \bar{N}]$$

为实际进入项目的总测度。其中， μ 表示勒贝格测度。进一步地，我们定义项目进入率：

$$\rho_t = \frac{n_t}{\bar{N}} \in [0, 1].$$

n_t 是制作者们在观察平台合同、预期收益和自身固定成本后，最终实际选择进入并开展项目的规模，而 ρ_t 是潜在项目中实际进入的比例。连续统设定并不意味着现实中存在“半个项目”，而是将大规模项目市场表示为确定性聚合近似。创作者的个体决策仍然是进入或不进入的离散选择。

2.2.2 创作资本与推荐资本

第 t 期期初的平台公共状态包含两类资本。第一类是创作资本

$$K_t \in \mathcal{K}, \quad \mathcal{K} = [0, \bar{K}].$$

K_t 表示生成式内容生态已经积累的生产性知识，包括经过市场验证的制作流程、可复用角色和场景资产、成熟创作者团队以及创作者账号声誉。它作用于内容生产而非推荐匹配。

令：

$$a_t = A(K_t, \tau) > 0$$

表示在不投入额外人工精修时，既有创作资本与基础人工智能技术能够提供的基础内容质量。其中 $\tau \geq 0$ 表示外生的生成式人工智能技术水平。

假设 2.1 (基础内容质量的单调性与创作资本边际收益递减). 函数 $A(K, \tau)$ 二阶连续可微，并满足：

$$A_K(K, \tau) > 0, \quad A_\tau(K, \tau) > 0, \quad A_{KK}(K, \tau) \leq 0. \quad (1)$$

假设2.1刻画创作资本和外生技术对基础内容质量的影响。成熟制作流程、可复用内容资产和创作者经验使项目在人工精修前即可达到更高质量，因此 $A_K(K, \tau) > 0$ 。基础技术进步改善内容生成、画面制作和后期处理能力，对应 $A_\tau(K, \tau) > 0$ 。创作体系成熟后，新增经验、数据和资产与既有积累更为重合，边际质量贡献弱递减，即 $A_{KK}(K, \tau) \leq 0$ 。

第二类是平台推荐资本：

$$M_t \in \mathcal{M}, \quad \mathcal{M} = [0, \bar{M}].$$

M_t 包括平台积累的用户需求数据、内容多模态表征能力、用户序列建模能力、跨域内容理解、语义索引以及项目筛选经验。其中 K_t 提高“作品本身能做到多好”， M_t 提高平台“能否识别作品并将其推荐给合适用户”的能力。这一划分与多模态表征模型在候选召回、排序特征和用户序列建模等多个推荐环节的应用相对应 [29]。

终端期基准模型先把推荐匹配效率标准化为 1，并令所有进入项目以相同的平均强度竞争注意力，从而得到合同与事后曝光的闭式解。动态部分再恢复 M_t ，并证明基

准模型是多模态匹配模型的一个特例。

2.2.3 项目固定成本

不同创作者或制作团队在技术能力、内容资产、版权资源和制作经验等方面存在差异，因而完成一个符合上线要求的生成式内容项目所需承担的前期成本并不相同。令项目 i 在第 t 期的固定制作成本为

$$k_{i,t} \sim F_k(\cdot | K_t, \tau),$$

其密度函数满足

$$f_k(\cdot | K_t, \tau) > 0$$

于相关支持集上成立。

固定制作成本 $k_{i,t}$ 是项目在获得播放收入之前必须承担的上线前支出，包括算力与模型会员费用、版权授权费用、角色与场景资产制作、人工后期、内容审核及发行准备等。该成本在项目进入以后成为沉没成本，因此影响创作者是否进入市场，但不直接影响其进入后的边际质量努力和平台曝光决策。

成本异质性反映了不同项目在制作效率和资源禀赋方面的差异。例如，拥有成熟工作流程、可复用角色资产和专业后期团队的创作者，通常能够以较低成本完成项目；缺乏相关经验或需要重新获取版权、制作素材的项目则面临较高的固定成本。本文假设创作者能够观察自身的固定成本，而平台只能掌握其总体分布，不能在签订统一合同之前完全识别每个项目的具体成本。

假设 2.2. 技术进步与创作资本的成本降低效应 对任意给定的固定成本 k ，有：

$$\frac{\partial F_k(k | K, \tau)}{\partial K} \geq 0, \quad \frac{\partial F_k(k | K, \tau)}{\partial \tau} \geq 0. \quad (\text{A2})$$

成本分布以当期生态创作资本 K_t 和外生人工智能技术水平 τ 为条件。该假设表示，创作资本积累和人工智能技术进步使固定成本分布以一阶随机占优意义向低成本方向移动。生态创作资本积累能够提高素材和流程的可复用程度，人工智能基础技术进步则能够降低内容生成、画面制作和后期处理的资源需求，二者均可能使项目固定成本整体下降。

为获得清晰的进入均衡和比较静态结果，基准模型采用均匀分布参数化：

$$k_{i,t} \sim U[0, \bar{k}(K_t, \tau)],$$

其中

$$\bar{k}_K(K_t, \tau) < 0, \quad \bar{k}_\tau(K_t, \tau) < 0.$$

因此， $\bar{k}_K < 0$ 和 $\bar{k}_\tau < 0$ 表示随着创作生态成熟或人工智能基础技术进步，成本分布的上界和平均水平同步下降。在其他条件不变时，原本固定成本过高的部分项目转为进入，市场潜在供给随之扩大。均匀分布用于简化进入固定点及其比较静态；一般连续成本分布下，项目进入仍遵循相同的成本阈值规则。

2.2.4 平台合同

在观察当期公共状态 (K_t, M_t) 和外生人工智能技术水平 τ 后，平台向所有符合条件的潜在项目公布统一合同：

$$C_t = (I_t, s_t),$$

其中：

$$I_t \in [0, \bar{I}]$$

表示平台向每个实际进入且符合条件的项目提供的固定投资、制作补贴或保底支付；而

$$s_t \in [0, 1]$$

表示创作者获得的可分配收入比例。相应地，平台保留的可分配收入比例为 $1 - s_t$ 。

固定支付 I_t 与项目最终实现的播放量和收入无关，主要用于补偿创作者的前期制作成本并缓解其进入约束。提高 I_t 会直接增加创作者项目进入后的预期净收益，使成本相对较高的潜在项目也可能选择进入。因此，固定支付主要作用于项目进入的外延边际。

由于 I_t 是每个实际进入项目获得的固定支付，当期进入项目的总测度为 n_t 时，平台承担的固定支付总额为

$$n_t I_t.$$

平台无法观察创作者的私人固定成本 $k_{i,t}$ ，因此不能依据固定成本实行完全价格歧视。

低固定成本项目可能由此获得正的信息租金。这意味着，提高单位项目补贴不仅会增加平台对既有进入项目的支付，还可能通过吸引更多项目进入进一步扩大总补贴支出。

收入分成 s_t 则属于与项目实现绩效挂钩的变量支付。较高的收入分成能够增加创作者从改善内容质量中获得的边际收益，从而强化其人工质量努力激励；但与此同时，更高的 s_t 会降低平台从每单位有效绩效中保留的收入，进而削弱平台在作品完成后继续追加推荐曝光的动力。因此，收入分成同时影响创作者的质量投入和平台的流量配置，平台需要在双方的边际激励之间进行权衡。

平台不能直接要求某个创作者必须进入市场，也不能直接选择实际进入项目的总规模 n_t 。潜在创作者在观察自身固定成本后，会根据固定支付 I_t 、收入分成 s_t 以及对未来推荐曝光的理性预期，比较进入项目所能获得的预期净收益与固定制作成本。平台只能通过改变合同条件间接影响这一比较，从而诱导项目进入。

平台合同有两项相互关联的功能：固定支付缓解进入阶段的固定成本约束，收入分成协调作品生产阶段的质量投入激励。二者通过项目进入规模、注意力拥堵和事后曝光相互作用，需要在同一问题中求解。

2.2.5 创作者质量努力

生成式内容项目进入市场后，项目创作者选择人工质量努力：

$$e_{i,t} \geq 0.$$

这里的人工质量努力，是指创作者在生成式人工智能提供的初始内容基础上，为改善作品质量而进行的额外投入，包括剧本修改、人物与镜头一致性处理、人工后期制作、事实核验、版权核验以及内容合规审查等。

本文假设该努力不可合同化：平台难以在项目开始前准确观察或验证创作者投入了多少有效努力，也难以将剧本修改质量、人物一致性处理和内容核验程度等多维活动完整写入合同。平台在作品完成后可以观察最终呈现的内容质量，但无法准确区分其中有多少来自人工智能技术和既有创作资本所决定的基础质量，又有多少来自创作者额外投入的人工努力。因此，平台不能直接规定创作者的努力水平，只能通过收入分成和后续推荐曝光间接激励其改善内容质量。

项目 i 在第 t 期形成的内容质量为：

$$q_{i,t} = a_t + e_{i,t},$$

其中， $a_t = A(K_t, \tau)$ 表示由当期生态创作资本和外生人工智能技术水平共同决定的基础内容质量， $e_{i,t}$ 表示创作者在此基础上进行人工修正和优化所带来的额外质量提升。该加法形式意味着，在基准模型中，人工质量努力对内容质量的边际贡献被标准化为 1，从而使分析集中于平台合同、创作者努力和推荐曝光之间的激励关系。若创作者不投入额外努力，即 $e_{i,t} = 0$ ，作品仍具有由人工智能工具和既有创作者生态所提供的基础质量 a_t 。

创作者的努力成本设定为：

$$C_e(e_{i,t}) = \frac{c}{2} e_{i,t}^2, \quad c > 0.$$

二次成本函数表示人工质量改进具有递增的边际成本。在较低努力水平下，创作者可以通过修正明显错误、改善基本镜头衔接等方式较容易地提高质量；但随着作品逐渐完善，进一步提升人物一致性、叙事完整性和制作精细度需要投入更多时间、专业人员和审核资源，因而新增一单位质量努力的成本不断上升。参数 c 衡量创作者实施人工质量改进的难度： c 越大，表示人工修正和后期优化成本越高，在其他条件相同的情况下，创作者选择的最优努力水平越低。

2.2.6 有效绩效、收入与曝光成本

生成式内容作品完成后，平台观察项目 i 的内容质量 $q_{i,t}$ ，并选择向该作品配置的实际推荐曝光：

$$x_{i,t} \geq 0.$$

变量 $x_{i,t}$ 表示平台通过推荐系统向作品配置的曝光强度，可以理解为测试流量、推荐展示机会或经过标准化处理的流量投入。本文假设平台不能在创作者投入质量努力之前完全承诺最终曝光，而是在作品完成并观察其质量以后，根据作品的潜在收益和流量机会成本决定推荐规模。因此，创作者在选择努力和决定是否进入时，需要理性预期平台后续的曝光行为。

项目的有效绩效为

$$Y_{i,t} = x_{i,t}q_{i,t}. \quad (2)$$

式(2)表示，作品的最终市场表现同时取决于平台提供的曝光和作品本身的内容质量。曝光决定作品能够接触多少潜在用户，质量则决定这些曝光能够以多高的效率转化为有效观看、用户留存或商业收益。在相同曝光下，质量更高的作品能够获得更多有效观看和互动；在相同质量下，更高的推荐曝光也能够扩大作品的实际传播范围。

$Y_{i,t}$ 定义为能够转化为收入和平台价值的有效绩效指标，可以对应经过质量调整的有效播放量、有效观看时长、用户互动量或综合变现绩效。乘法形式意味着，曝光与质量具有互补性：若作品质量较低，增加曝光的转化效率有限；若缺乏平台曝光，即使作品质量较高，也难以充分实现其市场价值。

每单位有效绩效产生 $r > 0$ 单位可分配货币收入。即一单位经过质量调整的有效播放、观看时长或用户互动平均能够转化为多少广告收入、付费收入或其他可分配商业收入。为突出平台合同与推荐激励之间的关系，基准模型将 r 视为外生且恒定的参数。因此，项目 i 产生的可分配收入为：

$$R_{i,t} = rY_{i,t}.$$

其中，创作者获得 $s_t r Y_{i,t}$ ，平台保留 $(1 - s_t) r Y_{i,t}$ 。

除可分配收入外，假定每单位有效绩效还为平台带来 $v \geq 0$ 单位不参与分账的当期价值，例如当期用户停留、交叉业务收益和平台活跃度。定义平台从一单位有效绩效中获得的剩余边际价值为：

$$\Lambda(s_t) = v + (1 - s_t)r.$$

平台从项目有效绩效中获得的当期总收益为：

$$\Lambda(s_t)Y_{i,t}.$$

v 只包含当期实现且不通过状态变量延续的平台价值。项目绩效形成的用户数据、制作经验和筛选能力统一通过下一期创作资本 K_{t+1} 、推荐资本 M_{t+1} 及未来价值函数 $V(K_{t+1}, M_{t+1})$ 计入，从而保持当期收益与动态收益的核算边界。

平台为项目配置曝光的机会成本为：

$$C_x(x_{i,t}; n_t) = \frac{\kappa(\nu + n_t)}{2} x_{i,t}^2, \quad \kappa > 0, \quad \nu > 0.$$

参数 ν 表示普通短视频、真人短剧、直播以及其他平台内容所形成的基础注意力竞争。即使当期没有目标类别的生成式内容项目进入，一部作品仍需与平台上的其他内容竞争用户注意力、推荐位置和测试流量，因此其曝光机会成本仍然为正。项目进入规模 n_t 则表示目标生成式内容类别项目供给扩张所产生的额外注意力拥堵。

参数 κ 表示平台推荐资源的总体稀缺程度，以及注意力竞争转化为曝光机会成本的强度。平台增加项目曝光的边际机会成本为

$$\frac{\partial C_x(x_{i,t}; n_t)}{\partial x_{i,t}} = \kappa(\nu + n_t)x_{i,t}.$$

因此， κ 越大，向某一项目追加曝光对其他内容造成的挤出越强，边际曝光成本随曝光规模上升得越快，平台向单个项目配置的最优曝光也越少。

2.2.7 当期收益

进入项目 i 的创作者收益为：

$$u_{i,t}^C = I_t - k_{i,t} + s_t r Y_{i,t} - \frac{c}{2} e_{i,t}^2.$$

平台从项目 i 获得的当期收益为：

$$u_{i,t}^P = \Lambda(s_t) Y_{i,t} - \frac{\kappa(\nu + n_t)}{2} x_{i,t}^2 - I_t.$$

若项目不进入，双方从该项目获得的当期收益均归一化为零。

2.2.8 行动顺序与有限承诺

每一期按照以下顺序进行：

1. 公共状态 (K_t, M_t) 与技术水平 τ 实现；
2. 平台公布合同 (I_t, s_t) ；

3. 潜在创作者观察自身固定成本，并形成对均衡进入规模的正确预期；
4. 创作者决定是否进入；
5. 实际进入的创作者选择质量努力；
6. 内容质量形成并被平台观察；
7. 平台推荐模块选择各项目的实际曝光；
8. 有效绩效实现，并按照既定分成结算；
9. 创作资本与推荐资本更新并进入下一期。

本文区分平台的前瞻性合同选择与作品上线后的事后推荐决策。平台在期初选择固定支付和收入分成时，考虑当期利润以及项目进入、质量投入和实现绩效对未来创作资本与推荐资本的影响。作品完成后，推荐模块在观察内容质量的基础上，按照平台当期边际收益与流量机会成本重新优化曝光。由于最终曝光并未写入可执行合同，平台不能在创作者投入质量努力之前可信地承诺确定的推荐流量。

长期经营的平台能够预见这一事后曝光反应，并将其纳入期初合同设计。因此，平台的合同选择具有前瞻性，而曝光配置具有事后最优性。这构成了本文所设定的有限承诺机制。

3 第二期：终端期基准均衡

第二期之后不存在进一步的状态价值。以下省略时间下标，并令：

$$a = A(K_2, \tau).$$

项目仅在固定成本方面存在异质性。固定成本在项目进入后成为沉没成本，因此所有进入项目在对称均衡中选择相同的努力、质量和曝光。本节暂时采用标准化的推荐环境：匹配效率等于 1，任意两个项目的平均注意力重叠等于 1。因此，项目规模 n 直接进入曝光成本。第6 节将恢复推荐资本和内容语义差异。

3.1 平台的事后曝光

给定项目质量 q 、收入分成 s 和进入规模 n ，推荐模块解决：

$$\max_{x \geq 0} \left\{ \Lambda(s)xq - \frac{\kappa(\nu + n)}{2}x^2 \right\}.$$

引理 3.1. 最优曝光 平台唯一最优曝光为：

$$x^*(q, n, s) = \frac{\Lambda(s)q}{\kappa(\nu + n)}. \quad (3)$$

并且：

$$\frac{\partial x^*}{\partial s} = -\frac{rq}{\kappa(\nu + n)} < 0, \quad \frac{\partial x^*}{\partial n} = -\frac{\Lambda(s)q}{\kappa(\nu + n)^2} < 0. \quad (4)$$

式(4)分别刻画了收入分成引致的平台流量投放效应和项目进入引致的注意力拥堵效应。

3.2 创作者的质量努力

创作者进入以后，固定支付 I 与固定成本 k 均不随质量努力变化。利用 $Y = xq$ 和 $q = a + e$ ，创作者与努力选择相关的变量净收益为

$$sr x(a + e) - \frac{c}{2}e^2.$$

将式(3)代入创作者的变量收益，定义：

$$\zeta(n, s) = \frac{2sr\Lambda(s)}{\kappa(\nu + n)}. \quad (5)$$

创作者在扣除固定投资与固定成本之前的变量目标为：

$$U^V(e; n, s, a) = \frac{\zeta(n, s)}{2}(a + e)^2 - \frac{c}{2}e^2.$$

假设 3.1. 努力问题的严格凹性

$$c > \max_{n \in [0, \bar{N}], s \in [0, 1]} \zeta(n, s).$$

该假设要求人工质量努力的边际成本上升速度高于合同激励与平台事后曝光共同产生的最大边际收益增长速度，从而保证创作者的努力选择问题在所有可行的收入分成和进入规模下均严格凹，并存在唯一且有限的最优努力水平。

由于 ζ 随 n 下降，其最大值在 $n = 0$ 处取得：

$$\max \zeta = \begin{cases} \frac{(v+r)^2}{2\kappa\nu}, & v < r, \\ \frac{2rv}{\kappa\nu}, & v \geq r. \end{cases}$$

引理 3.2. 最优努力、质量、曝光与绩效 在假设 3.1 下，创作者的唯一最优努力为：

$$e^*(n, s, a) = \frac{\zeta(n, s)a}{c - \zeta(n, s)}.$$

相应的内容质量为：

$$q^*(n, s, a) = \frac{ca}{c - \zeta(n, s)}.$$

平台曝光和有效绩效分别为：

$$\begin{aligned} x^*(n, s, a) &= \frac{\Lambda(s)q^*(n, s, a)}{\kappa(\nu + n)}, \\ Y^*(n, s, a) &= \frac{\Lambda(s)[q^*(n, s, a)]^2}{\kappa(\nu + n)}. \end{aligned}$$

创作者在扣除固定投资和固定成本之前获得的变量剩余为：

$$\begin{aligned} S(n, s, a) &= srY^*(n, s, a) - \frac{c}{2}[e^*(n, s, a)]^2 \\ &= \frac{c\zeta(n, s)a^2}{2[c - \zeta(n, s)]}. \end{aligned}$$

平台从每个进入项目获得的经营收益为：

$$\begin{aligned} g(n, s, a) &= \Lambda(s)Y^*(n, s, a) - \frac{\kappa(\nu + n)}{2}[x^*(n, s, a)]^2 \\ &= \frac{\Lambda(s)^2[q^*(n, s, a)]^2}{2\kappa(\nu + n)}. \end{aligned}$$

由于：

$$\zeta_n(n, s) < 0,$$

可得：

$$e_n^* < 0, \quad q_n^* < 0, \quad S_n < 0, \quad Y_n^* < 0.$$

因此，项目进入增加会产生两层相互强化的拥堵效应。第一，进入项目数量增加提高了平台向单个项目配置曝光的机会成本，即使内容质量保持不变，也会通过分母 $\nu + n$ 直接降低单个项目的均衡曝光。第二，预期曝光下降会降低创作者提高内容质量所能获得的边际分成收益，使综合质量激励强度 $\zeta(n, s)$ 下降，进而减少其最优质量努力和最终内容质量。质量下降又会进一步削弱平台的曝光投放和项目的有效绩效。因此，项目供给扩张不仅导致推荐流量在更多项目之间被直接稀释，还会通过削弱创作者的质量投入激励，进一步降低单个项目的曝光和市场表现。

4 项目进入均衡

4.1 进入条件与均衡定义

项目 i 选择进入，当且仅当：

$$I + S(n, s, a) - k_i \geq 0.$$

$k^*(n, s, a, I) = I + S(n, s, a)$ 表示边际进入项目的固定成本。

所有满足 $k_i \leq k^*(n, s, a, I)$ 的项目均选择进入。由于潜在项目的总测度为 $\bar{N}$ ，固定成本不超过该临界值的项目比例为 $F_k(k^* | K, \tau)$ ，因此实际进入规模满足：

$$n = \bar{N} F_k(I + S(n, s, a) | K, \tau). \quad (6)$$

式(6)是项目进入的理性预期不动点。预期进入规模影响平台曝光和项目收益，所有创作者的进入决策聚合后产生的实际进入规模又必须与该预期一致。

定义 4.1. 项目进入均衡 给定状态 (K, τ) 和平台合同 (I, s) ，项目进入均衡是满足式(6)的进入规模：

$$n^e(I, s, K, \tau) \in [0, \bar{N}].$$

命题 4.1. 进入均衡的存在性与唯一性 若 F_k 连续且弱递增，则对任意合同 (I, s) ，项目进入均衡存在且唯一。

证明. 定义:

$$\Phi(n) = \bar{N}F_k(I + S(n, s, a)|K, \tau).$$

由于 $S_n < 0$ 且 F_k 弱递增, $\Phi(n)$ 关于 n 弱递减. 又有 $\Phi(0) \geq 0$ 和 $\Phi(\bar{N}) \leq \bar{N}$, 故连续函数 $\Phi(n) - n$ 至少存在一个零点. 由于 $\Phi(n) - n$ 严格递减, 零点唯一. 证毕. $\square$

4.2 固定投资的扩量与质量稀释效应

进入均衡满足:

$$n^e = \bar{N}F_k(I + S(n^e, s, a)|K, \tau),$$

由于右边的 S 也依赖于 n , 所以对 I 求导时, 不能只求 I 的直接影响, 还要考虑 I 使 n 变化、进而使 S 变化的间接反馈. 对上式关于 I 求全导数:

$$\frac{\partial n^e}{\partial I} = \bar{N}f_k(k^*|K, \tau) \left(1 + S_n \frac{\partial n^e}{\partial I} \right),$$

其中:

$$k^* = I + S(n^e, s, a).$$

整理得到:

$$[1 - \bar{N}f_k(k^*|K, \tau)S_n] \frac{\partial n^e}{\partial I} = \bar{N}f_k(k^*|K, \tau).$$

所以定义:

$$\Delta = 1 - \bar{N}f_k(k^*|K, \tau)S_n(n^e, s, a)$$

就有:

$$\frac{\partial n^e}{\partial I} = \frac{\bar{N}f_k(k^*|K, \tau)}{\Delta}.$$

由于 $S_n < 0$, 有 $\Delta > 1$, 所以可得:

$$\frac{\partial n^e}{\partial I} = \frac{\bar{N}f_k(k^*|K, \tau)}{\Delta} > 0.$$

命题 4.2. 普惠固定投资的扩量与稀释效应 提高单位项目固定投资会扩大实际进入规模:

$$\frac{\partial n^e}{\partial I} > 0.$$

但固定投资通过进入拥堵降低单项目的努力、曝光、绩效和变量剩余：

$$\begin{aligned} \frac{de^*}{dI} &= e_n^* \frac{\partial n^e}{\partial I} < 0, \\ \frac{dx^*}{dI} < 0, \quad \frac{dY^*}{dI} < 0, \quad \frac{dS}{dI} < 0. \end{aligned}$$

固定投资因而具有扩量效应与质量稀释效应。它能够迅速扩大内容供给，却可能压低每个项目的预期流量、质量投入和变量收益。

4.3 收入分成的双边激励效应

在给定进入规模时：

$$\zeta_s(n, s) = \frac{2r[v + r - 2rs]}{\kappa(\nu + n)}.$$

若 $v < r$ ，定义临界分成：

$$s^\dagger = \frac{v + r}{2r} \in (0, 1).$$

考虑进入规模的内生反应后，有：

$$\frac{\partial n^e}{\partial s} = \frac{\bar{N} f_k(k^*|K, \tau) S_s}{\Delta}.$$

以及：

$$\frac{d\zeta}{ds} = \frac{\zeta_s}{\Delta}.$$

命题 4.3. 收入分成、项目进入与质量努力 若 $v < r$ ，则在 $s < s^\dagger$ 时：

$$\frac{\partial n^e}{\partial s} > 0, \quad \frac{de^*}{ds} > 0;$$

在 $s > s^\dagger$ 时：

$$\frac{\partial n^e}{\partial s} < 0, \quad \frac{de^*}{ds} < 0.$$

若 $v \geq r$ ，收入分成对项目进入和质量努力在可行区间内弱单调增加。

上述结果取决于平台不参与分账的单位绩效价值 v 与可分配收入货币化率 r 的相对大小。综合质量激励强度 $\zeta(n, s)$ 同时取决于创作者获得的收入比例 s 和平台从有效绩效中获得的剩余边际价值 $\Lambda(s) = v + (1 - s)r$ 。

当 $v < r$ 时，平台的项目收益较多依赖可分配收入。适度提高收入分成能够增强创作者的质量投入激励，并提高项目变量剩余和进入规模；但当收入分成超过临界水平 $s^\dagger$ 后，平台保留的可分配收入下降较快，作品完成后的推荐曝光激励随之减弱。事后曝光下降产生的负面效应超过创作者分成比例提高带来的正面效应，因而项目进入和质量努力均开始下降。

当 $v \geq r$ 时，平台从用户停留、交叉业务和生态活跃度等不参与分账的渠道获得较高价值。即使收入分成提高，平台仍然具有较强的事后曝光动力，因此创作者激励改善的正面效应在整个可行区间内不会被平台曝光收缩所逆转。收入分成对项目进入和质量努力因而呈弱单调正向影响。

4.4 最优收入分成的上界

命题 4.4. 过高收入分成的支配关系 假定 $v < r$ 。对任意 $s > s^\dagger$ ，定义：

$$\tilde{s} = 1 + \frac{v}{r} - s.$$

则：

$$0 \leq \tilde{s} < s^\dagger < s \leq 1.$$

合同 $\tilde{s}$ 与合同 s 对任意给定进入规模诱导相同的创作者努力、质量与变量剩余；给定相同固定投资，两份合约也诱导相同的进入均衡。但合同 $\tilde{s}$ 为平台带来更高经营收益。因此，终端期平台的任一最优收入分成都满足：

$$s^P \leq s^\dagger.$$

证明. 由 $\Lambda(s) = v + (1 - s)r$ 可得：

$$\tilde{s}r = \Lambda(s), \quad \Lambda(\tilde{s}) = sr.$$

因此：

$$\tilde{s}r\Lambda(\tilde{s}) = sr\Lambda(s),$$

两份合同具有相同的 ζ ，从而诱导相同的 e^* 、 q^* 、 S 和进入固定点。由于 $s > s^\dagger$ ，有 $\Lambda(\tilde{s}) > \Lambda(s)$ ，故平台在 $\tilde{s}$ 下获得更高经营收益。□

4.5 技术进步与项目进入

在固定合同 (I, s) 下：

$$\begin{aligned}\frac{\partial n^e}{\partial \tau} &= \frac{\bar{N}[f_k(k^*|K, \tau)S_a A_\tau + F_{k,\tau}(k^*|K, \tau)]}{\Delta}, \\ \frac{\partial n^e}{\partial K} &= \frac{\bar{N}[f_k(k^*|K, \tau)S_a A_K + F_{k,K}(k^*|K, \tau)]}{\Delta}.\end{aligned}$$

命题 4.5. 人工智能技术、创作资本与项目进入 在假设 3.1 和假设 2.1 下：

$$\frac{\partial n^e}{\partial \tau} > 0, \quad \frac{\partial n^e}{\partial K} > 0.$$

人工智能技术对单项目努力的总效应一般不确定：

$$\frac{de^*}{d\tau} = e_a^* A_\tau + e_n^* \frac{\partial n^e}{\partial \tau}.$$

命题 4.5 表明，人工智能技术进步和创作资本积累均通过两条渠道扩大项目进入规模。第一，二者提高基础内容质量，从而增加创作者进入后能够获得的变量剩余，提高固定成本进入门槛。第二，二者使固定成本分布向低成本方向移动，使更多潜在项目在给定进入门槛下具备进入条件。进入规模扩大后产生的注意力拥堵会降低单项目变量剩余，因而分母 $\Delta > 1$ 对上述直接扩量效应形成部分抵消，但不会改变均衡进入规模增加的方向。

项目进入增加不会自动改善单个项目的投入和表现。技术进步一方面通过提高基础质量，增加创作者质量努力的边际回报，形成正向的直接生产率效应；另一方面，技术进步和成本下降会吸引更多项目进入，加剧注意力竞争并降低单项目预期曝光，形成负向的进入拥堵效应。两种力量的相对大小决定技术进步对单项目质量努力的总效应；单项目曝光、有效绩效和变量收益也具有同样的不确定性。技术进步可以显著扩大项目供给，其收益同时受到更激烈注意力竞争的抵消。

5 平台合同的当期选择

5.1 爆款发现价值与筛选成本

令：

$$\mathcal{B}(n)$$

表示平台从项目组合中发现高潜力题材、制作团队或爆款作品所获得的额外当期组合价值，即“扩大项目试验范围”带来的价值，而非普通项目的播放收入。

假设 5.1. 爆款发现的边际收益递减

$$\mathcal{B}(0) = 0, \quad \mathcal{B}'(n) > 0, \quad \mathcal{B}''(n) < 0.$$

其中， $\mathcal{B}(0) = 0$ 表示如果没有任何项目进入，平台就不可能通过这批项目发现爆款，因此爆款发现价值为零。

$\mathcal{B}'(n) > 0$ 表示扩大项目池能够增加题材和团队的试验广度， $\mathcal{B}''(n) < 0$ 则概括题材覆盖趋于饱和、项目相似度上升以及有限筛选能力共同造成的边际发现价值递减。该项只保留“扩大试验集合”的当期组合价值；项目形成的跨期数据和知识价值将在后文通过状态转移单独计入，避免重复计算。

一个可供数值分析使用的参数化形式为：

$$\mathcal{B}(n) = \bar{b}[1 - \exp(-\lambda n)], \quad \bar{b} > 0, \quad \lambda > 0.$$

平台还承担项目筛选、版权核验和内容审核成本：

$$C'_N(n) \geq 0, \quad C''_N(n) > 0.$$

条件 $C'_N(n) \geq 0$ 表示项目数量增加不会降低平台承担的筛选与审核总成本，其中弱不等号允许平台在项目规模为零或较低时利用既有审核能力，使初始边际成本为零。条件 $C''_N(n) > 0$ 表示随着项目数量扩大，审核资源逐渐趋于饱和，新增项目所需承担的边际筛选、版权核验和合规成本严格上升。

5.2 平台利润

平台当期总利润为：

$$\pi(K, I, s) = \int_{\mathcal{E}} \left[\Lambda(s) Y_i - \frac{\kappa(\nu + n)}{2} x_i^2 - I \right] di + \omega \mathcal{B}(n) - C_N(n), \quad (7)$$

其中

$$n = n^e(I, s, K, \tau).$$

在对称均衡中，式(7)简化为：

$$\pi(K, I, s) = n^e [g(n^e, s, A(K, \tau)) - I] + \omega \mathcal{B}(n^e) - C_N(n^e).$$

平台实际只能选择合同 (I, s) ，而不能直接选择进入规模。

5.3 目标进入规模的可实施性

平台通过固定支付 I 、收入分成 s 以及创作者对后续曝光的预期影响进入规模，而非直接选择 n 。给定收入分成 s ，以下实施问题求出目标进入规模 n 所需的固定支付，并刻画非负固定支付能够实施的规模集合。

给定公共状态 (K, τ) ，项目固定成本服从条件分布 $F_k(\cdot | K, \tau)$ 。由于潜在项目的总测度为 $\bar{N}$ ，若平台希望有 $n \in [0, \bar{N}]$ 个项目进入，则进入项目占潜在项目池的比例为 $n/\bar{N}$ 。相应地，定义边际进入项目的固定成本为

$$\chi(n; K, \tau) = F_k^{-1} \left(\frac{n}{\bar{N}} \mid K, \tau \right).$$

$\chi(n; K, \tau)$ 表示在固定成本由低到高排列的情况下，为实现 n 个项目进入，成本最高的进入项目所承担的固定成本。所有固定成本低于 $\chi(n; K, \tau)$ 的项目均选择进入，而固定成本高于该临界值的项目不进入。

在成本分布的内部支持区间内，由逆函数求导法则可得

$$\chi_n(n; K, \tau) = \frac{1}{\bar{N} f_k(\chi(n; K, \tau) | K, \tau)} > 0.$$

因此，目标进入规模越大，平台需要吸引的边际项目固定成本越高。这一结果反映了

项目按照固定成本由低到高依次进入的选择机制。

给定目标进入规模 n 和收入分成 s ，创作者进入后能够获得的变量剩余为

$$S(n, s, A(K, \tau)).$$

若平台希望恰好实施目标进入规模 n ，则边际进入项目必须在进入与不进入之间恰好无差异，即

$$I + S(n, s, A(K, \tau)) - \chi(n; K, \tau) = 0.$$

因此，精确实施目标进入规模 n 所需要的单位固定支付为

$$\Psi(n; s, K, \tau) = \chi(n; K, \tau) - S(n, s, A(K, \tau)). \quad (8)$$

函数 $\Psi(n; s, K, \tau)$ 可以称为目标进入规模的实施支付函数。它表示，在给定收入分成和公共状态的情况下，平台为了使边际项目恰好愿意进入，需要向每个进入项目提供的固定支付。

式(8)把目标进入规模映射为平台实际选择的固定支付 I 。若平台选择

$$I = \Psi(n; s, K, \tau),$$

则有

$$I + S(n, s, A(K, \tau)) = \chi(n; K, \tau).$$

根据式(5.3)，固定成本低于该临界值的项目比例恰好为 $n/\bar{N}$ ，因而 n 满足进入固定点：

$$n = \bar{N} F_k \left(I + S(n, s, A(K, \tau)) \mid K, \tau \right).$$

结合进入均衡的唯一性，平台选择 $I = \Psi(n; s, K, \tau)$ 时，实际形成的均衡进入规模恰好等于目标规模 n 。

反之，若固定支付 I 诱导的均衡进入规模为 $n^e(I, s, K, \tau)$ ，则边际进入项目的无差异条件意味着

$$I = \Psi(n^e(I, s, K, \tau); s, K, \tau).$$

因此， Ψ 建立了固定支付 I 与其所诱导的均衡进入规模之间的单调对应关系。

由式(8)可得

$$\Psi_n(n; s, K, \tau) = \chi_n(n; K, \tau) - S_n(n, s, A(K, \tau)). \quad (9)$$

由于

$$\chi_n(n; K, \tau) > 0, \quad S_n(n, s, A(K, \tau)) < 0,$$

因而

$$\Psi_n(n; s, K, \tau) > 0. \quad (10)$$

实施支付随目标进入规模严格增加包含两种相互强化的经济力量。第一，目标进入规模扩大意味着平台需要吸引固定成本更高的边际项目，因而边际进入成本 $\chi(n; K, \tau)$ 上升。第二，项目数量增加会加剧注意力拥堵，降低单个项目的预期曝光、质量努力和变量剩余，即 $S_n < 0$ 。因此，平台不仅需要补偿新增项目更高的固定成本，还需要补偿所有项目因进入拥堵而减少的变量收益。两种效应共同使实施更大进入规模所需的单位固定支付上升。

给定收入分成 s 和公共状态 (K, τ) ，定义零补贴进入规模为

$$n^0(s, K, \tau) = n^e(0, s, K, \tau). \quad (11)$$

$n^0(s, K, \tau)$ 表示平台不提供任何固定投资、制作补贴或收入保底时，仍然愿意主动进入的项目规模。

在内部进入均衡下，零补贴进入规模满足

$$\Psi(n^0(s, K, \tau); s, K, \tau) = 0. \quad (12)$$

此时，边际项目仅依靠收入分成和预期绩效所产生的变量剩余，即可恰好覆盖其固定制作成本：

$$S(n^0, s, A(K, \tau)) = \chi(n^0; K, \tau).$$

进一步假设平台的单位固定支付受到约束：

$$I \in [0, \bar{I}],$$

其中 $\bar{I} > 0$ 表示平台能够向单个项目提供的最高固定支付。定义最高固定支付下能够实施的最大进入规模为

$$n^{\bar{I}}(s, K, \tau) = \sup \left\{ n \in [0, \bar{N}] : \Psi(n; s, K, \tau) \leq \bar{I} \right\}. \quad (13)$$

若该解位于内部，则满足

$$\Psi(n^{\bar{I}}(s, K, \tau); s, K, \tau) = \bar{I}.$$

命题 5.1. 非负统一支付下的可实施进入集合 给定收入分成 s 和公共状态 (K, τ) ，若平台只能选择 $I \in [0, \bar{I}]$ 的统一非负固定支付，则平台能够精确实施的目标进入规模集合为

$$\mathcal{N}_I(s, K, \tau) = \left\{ n \in [0, \bar{N}] : 0 \leq \Psi(n; s, K, \tau) \leq \bar{I} \right\}. \quad (14)$$

由于 $\Psi_n(n; s, K, \tau) > 0$ ，该集合为区间

$$\mathcal{N}_I(s, K, \tau) = [n^0(s, K, \tau), n^{\bar{I}}(s, K, \tau)]. \quad (15)$$

证明. 若目标进入规模 n 能够由某个固定支付 $I \in [0, \bar{I}]$ 精确实施，则边际进入项目的无差异条件要求

$$I = \Psi(n; s, K, \tau).$$

因此，必要条件是

$$0 \leq \Psi(n; s, K, \tau) \leq \bar{I}.$$

反之，若某个 $n \in [0, \bar{N}]$ 满足

$$0 \leq \Psi(n; s, K, \tau) \leq \bar{I},$$

则平台可以选择

$$I = \Psi(n; s, K, \tau).$$

在该固定支付下，边际进入项目恰好满足进入无差异条件，固定成本低于边际成本 $\chi(n; K, \tau)$ 的项目比例为 $n/\bar{N}$ ，因而 n 满足进入固定点。由进入均衡的唯一性，实际均衡进入规模恰好为 n 。

最后，由 $\Psi_n > 0$ 可知，实施支付关于目标进入规模严格递增。结合

$$\Psi(n^0; s, K, \tau) = 0$$

以及 $n^{\bar{I}}$ 的定义，可得可实施集合为

$$\left[n^0(s, K, \tau), n^{\bar{I}}(s, K, \tau) \right].$$

□

命题5.1表明，统一非负固定支付是一种只能在零补贴进入规模基础上继续扩大项目进入的单向政策工具。若平台希望实施的目标规模满足

$$n < n^0(s, K, \tau),$$

则由 $\Psi_n > 0$ 和 $\Psi(n^0) = 0$ 可得

$$\Psi(n; s, K, \tau) < 0.$$

精确实施该目标规模需要平台设置负固定支付，即向项目收取进入费。若合同空间只允许平台提供非负固定支付，则低于零补贴进入规模的目标无法通过统一补贴合同实施。

类似地，若

$$n > n^{\bar{I}}(s, K, \tau),$$

则实施该目标规模所需的固定支付超过 $\bar{I}$ ，同样不在平台的可行合同空间内。因此，零补贴进入规模 n^0 构成统一非负支付下的进入下限，而 $n^{\bar{I}}$ 构成最高固定支付约束下的进入上限。

这一结果具有重要的政策含义。随着生成式人工智能技术进步和创作资本积累，项目固定成本下降、基础内容质量和变量收益提高，零补贴条件下也可能有越来越多的项目主动进入。当 $n^0(s, K, \tau)$ 已经处于较高水平时，平台即使将固定补贴降至零，也只能把项目进入规模降低到 n^0 ，无法继续通过削减补贴压缩供给。若平台希望将项目数量控制在 n^0 以下，则必须引入固定支付之外的准入工具，例如资格审核、项目申请制、上传数量限制、题材配额或进入费。由此，产业成熟阶段的平台政策可能由普遍性

固定支持逐步转向更严格的资格筛选和准入控制。

6 多模态推荐与一般化期内均衡

6.1 推荐资本、匹配效率与语义拥堵

基准模型将项目质量 q_i 直接解释为每单位曝光的有效转化能力，因而 $Y_i = x_i q_i$ 。这一设定适合突出合同机制，但没有区分垂直内容质量与用户对题材、画风和叙事类型的横向偏好。多模态表征技术的实际用途表明，平台可以联合利用文本、封面、图像和视频帧识别内容，并在候选召回、排序特征和用户序列建模等环节改善内容与用户的匹配 [29]。因此，本节引入推荐资本 M ，将基准模型推广为一个仍可解析的简化匹配模型。

令

$$\eta(M) \in (0, 1]$$

表示平台把内容质量转化为有效用户匹配的效率。给定原始曝光 x_i 和内容质量 q_i ，项目有效绩效改写为

$$Y_i^R = x_i \eta(M) q_i. \quad (16)$$

$\eta(M)$ 同时概括内容识别精度、冷启动识别能力和把内容送达合适用户后的转化效率。本文用这一约化参数连接推荐技术与经济绩效；WeMM-Embedding 的基准测试分数只提供技术背景，不直接映射为该参数。

进一步令 $D \in [0, 1]$ 表示当期进入项目的内容多样性，数值越大表示题材、叙事和视觉风格的平均差异越大。定义

$$\vartheta(M, D) \in (0, 1]$$

为项目之间的有效注意力重叠程度，并将曝光机会成本写为

$$C_x^R(x_i; n, M, D) = \frac{\kappa[\nu + \vartheta(M, D)n]}{2} x_i^2. \quad (17)$$

若全部项目争夺完全相同的用户， $\vartheta = 1$ ；若项目服务于差异较大的用户群体，则 ϑ 较低。式(17)也可以由内容嵌入的平均相似度得到。令 z_i 为项目 i 的多模态表示，

$\omega(z_i, z_j; M) \in [0, 1]$ 为平台识别到的两个项目之间的有效替代程度，则对任意项目 i ,

$$\vartheta(M, D)n = \int_{j \in \mathcal{E}} \omega(z_i, z_j; M) dj$$

是对称环境下的约化表达。因此，基准模型中的 n 实际上对应“全部新增项目均为完全替代品”的边界情形。

假设 6.1 (推荐技术与语义分流). 函数 η 与 ϑ 二阶连续可微，并满足

$$\eta_M > 0, \quad \eta_{MM} \leq 0, \quad \vartheta_M \leq 0, \quad \vartheta_D < 0.$$

该假设允许推荐资本通过两条渠道发挥作用。第一， $\eta_M > 0$ 表示更好的内容表征和用户理解提高匹配转化效率；第二， $\vartheta_M \leq 0$ 表示平台能够减少原本因识别粗糙而产生的无效流量竞争。 $\vartheta_D < 0$ 则表示，在项目数相同的情况下，内容越多样，项目间的有效注意力重叠越小。

6.2 一般化曝光、努力与进入

给定 q, n, s, M, D ，推荐模块在作品形成后解决

$$\max_{x \geq 0} \left\{ \Lambda(s)x\eta(M)q - \frac{\kappa[\nu + \vartheta(M, D)n]}{2}x^2 \right\}.$$

定义有效拥堵项

$$H(n, M, D) = \nu + \vartheta(M, D)n.$$

则事后最优曝光为

$$x^R(q, n, s, M, D) = \frac{\Lambda(s)\eta(M)q}{\kappa H(n, M, D)}. \quad (18)$$

将式(18)代入创作者问题，定义一般化激励强度

$$\zeta^R(n, s, M, D) = \frac{2sr\Lambda(s)\eta(M)^2}{\kappa H(n, M, D)}. \quad (19)$$

并假设

$$c > \sup_{n, s, M, D} \zeta^R(n, s, M, D),$$

从而创作者努力问题在扩展模型中仍严格凹。

命题 6.1. 多模态匹配下的期内均衡 给定 (n, s, K, M, D, τ) , 令 $a = A(K, \tau)$ 。扩展模型的唯一对称期内均衡满足

$$e^R = \frac{\zeta^R a}{c - \zeta^R}, \quad q^R = \frac{ca}{c - \zeta^R}, \quad (20)$$

$$x^R = \frac{\Lambda(s)\eta(M)q^R}{\kappa H}, \quad Y^R = \frac{\Lambda(s)\eta(M)^2(q^R)^2}{\kappa H}, \quad (21)$$

$$S^R = \frac{c\zeta^R a^2}{2(c - \zeta^R)}, \quad g^R = \frac{\Lambda(s)^2\eta(M)^2(q^R)^2}{2\kappa H}. \quad (22)$$

在固定 n, s, K, D 时, 推荐资本提高努力、质量、曝光、绩效和创作者变量剩余:

$$e_M^R > 0, \quad q_M^R > 0, \quad x_M^R > 0, \quad Y_M^R > 0, \quad S_M^R > 0.$$

在固定 n, s, K, M 时, 提高内容多样性也具有同方向作用。令 $(\eta, \vartheta) = (1, 1)$, 上述结果退化为第3节的基准模型。

证明. 平台曝光问题的一阶条件直接给出式(18)。创作者的变量目标为

$$\frac{\zeta^R}{2}(a + e)^2 - \frac{c}{2}e^2,$$

因而其解与基准模型具有相同形式。其余表达式由代入得到。进一步地,

$$\frac{\zeta_M^R}{\zeta^R} = 2\frac{\eta_M}{\eta} - \frac{\vartheta_M n}{H} > 0,$$

且

$$\frac{x_M^R}{x^R} = \frac{\eta_M}{\eta} + \frac{q_M^R}{q^R} - \frac{\vartheta_M n}{H} > 0.$$

由 $\vartheta_D < 0$ 可同理得到关于 D 的结论。 $\square$

给定合同, 扩展模型的进入均衡由

$$n^R = \bar{N}F_k \left(I + S^R(n^R, s, A(K, \tau), M, D) \mid K, \tau \right) \quad (23)$$

决定。在固定 D 时, $S_n^R < 0$, 故基准模型的存在性和唯一性证明仍然成立。定义

$$\Delta^R = 1 - \bar{N}f_k S_n^R > 1,$$

则

$$\frac{\partial n^R}{\partial M} = \frac{\bar{N} f_k S_M^R}{\Delta^R} > 0, \quad \frac{\partial n^R}{\partial D} = \frac{\bar{N} f_k S_D^R}{\Delta^R} > 0. \quad (24)$$

推荐资本提高后，新项目更容易被识别和匹配，零补贴条件下的自主进入规模随之上升。新增项目与既有项目高度相似时，较大的 ϑ 使进入拥堵压低单项目努力和曝光；新增项目服务于不同用户群时，拥堵效应明显减弱。因此，项目增加造成同等程度流量稀释的结论只适用于内容高度同质的情形。

7 两期离散时间模型：第一期与向后归纳

7.1 状态转移

两期模型的时期为 $t \in \{1, 2\}$ 。每一期代表一个完整经营批次，而不是一次单独曝光。第 1 期产生的制作经验、内容资产、用户反馈和语义覆盖在期末汇总，并在第 2 期期初形成新的状态。令

$$\mathcal{H}_t = n_t e_t^R, \quad \mathcal{P}_t = n_t Y_t^R$$

分别表示当期进入项目的总人工质量投入和总有效绩效。状态转移为

$$K_{t+1} = (1 - \delta_K) K_t + G_K(n_t, \mathcal{H}_t), \quad (25)$$

$$M_{t+1} = (1 - \delta_M) M_t + G_M(n_t, D_t, \mathcal{P}_t), \quad (26)$$

其中 $\delta_K, \delta_M \in [0, 1]$ 为折旧率。创作资本来自进入团队和人工精修所沉淀的流程、角色资产与制作经验；推荐资本来自内容覆盖、题材多样性和用户反馈。状态更新是本文在批次层面的经济聚合；Zhou et al. [29] 提供推荐技术的工程背景，不提供上述离散转移方程。

假设 7.1 (资本积累). G_K 与 G_M 连续、递增且联合凹，并满足

$$G_{K,n}, G_{K,\mathcal{H}} > 0, \quad G_{M,n}, G_{M,D}, G_{M,\mathcal{P}} > 0.$$

两个转移函数将状态空间映射回 $\mathcal{K} \times \mathcal{M}$ 。

严格递增的原始投入并不意味着提高固定补贴必然增加下一期资本，因为补贴在扩大 n_t 的同时可能降低单项目 e_t^R 和 Y_t^R 。因此，动态效应需要考察总投入 $\mathcal{H}_t$ 与总绩

效 $\mathcal{P}_t$ ，而不能只看项目数。

7.2 第二期价值与第一期问题

在给定当期进入组合时，用 $D = D(I, s, K, M)$ 表示合同诱导的内容多样性，并将式(23)的解简记为 $n^R(I, s, K, M)$ 。平台的一般化当期利润为

$$\Pi(K, M, I, s) = n^R \left[g^R(n^R, s, A(K, \tau), M, D) - I \right] + \omega \mathcal{B}(n^R) - C_N(n^R). \quad (27)$$

为保证进入固定点的唯一性，下文要求合同引致的多样性变化不足以逆转 $S_n^R < 0$ 。若内容组合固定，这一条件自动满足。

第 2 期为终端期，因此平台价值为

$$V_2(K_2, M_2) = \max_{I_2 \in [0, \bar{I}], s_2 \in [0, 1]} \Pi(K_2, M_2, I_2, s_2). \quad (28)$$

式(28)由第3节的向后求解逻辑以及本节的多模态推广共同确定。给定第二期价值函数，第 1 期平台解决

$$V_1(K_1, M_1) = \max_{I_1 \in [0, \bar{I}], s_1 \in [0, 1]} \{ \Pi(K_1, M_1, I_1, s_1) + \beta V_2(K_2, M_2) \}, \quad (29)$$

其中 $\beta \in (0, 1)$ ， (K_2, M_2) 由式(25)和式(26)决定。式(28)与式(29)构成完整的 $t = 1, 2$ 离散时间模型。

7.3 目标进入表示与动态边际价值

直接对固定支付求导可以得到标准的合同一阶条件，但不能直观区分“扩大多少项目”和“用什么工具实施”。为提取核心经济楔子，以下利用严格递增的实施支付函数，把固定支付重新参数化为目标进入规模。令合同诱导的多样性写为 $D(n, s, K, M)$ ，定义一般化实施支付

$$\Psi^R(n; s, K, M) = \chi(n; K, \tau) - S^R(n, s, A(K, \tau), M, D(n, s, K, M)). \quad (30)$$

假定多样性的内生变化不足以抵消边际项目成本上升与进入拥堵，从而 $\Psi_n^R > 0$ 。相应的零补贴自然进入规模 $n^{0,R}(s, K, M)$ 由

$$\Psi^R(n^{0,R}; s, K, M) = 0 \quad (31)$$

唯一确定。

若允许实施支付取正值或负值，平台选择目标 n 等价于选择 $I = \Psi^R(n; s, K, M)$ 。将支付代回平台利润，得到目标进入表示下的当期利润

$$\tilde{\Pi}(K, M, n, s) = n \left[g^R(n, s, A(K, \tau), M, D) - \Psi^R(n; s, K, M) \right] + \omega \mathcal{B}(n) - C_N(n). \quad (32)$$

对应的状态转移记为

$$\tilde{T}_K(K, M, n, s) = (1 - \delta_K)K + G_K(n, ne^R), \quad (33)$$

$$\tilde{T}_M(K, M, n, s) = (1 - \delta_M)M + G_M(n, D, nY^R). \quad (34)$$

这里 e^R, Y^R, D 均取合同和进入规模诱导的均衡值。目标进入表示只是对原合同问题的单调变换；当 $\Psi^R < 0$ 时，它同时揭示了统一非负支付的工具约束。

固定 s_1 ，定义第一期目标进入的动态边际价值

$$\begin{aligned} \Omega_1(n_1; K_1, M_1, s_1) &:= \tilde{\Pi}_n + \beta V_{2,K} \tilde{T}_{K,n} + \beta V_{2,M} \tilde{T}_{M,n} \\ &=: \underbrace{\tilde{\Pi}_n}_{\text{当期边际利润}} + \underbrace{\beta V_{2,K} \tilde{T}_{K,n}}_{\text{创作资本价值}} + \underbrace{\beta V_{2,M} \tilde{T}_{M,n}}_{\text{推荐学习价值}}. \end{aligned} \quad (35)$$

其中

$$\begin{aligned} \tilde{T}_{K,n} &= G_{K,n} + G_{K,H}(e^R + ne_n^R), \\ \tilde{T}_{M,n} &= G_{M,n} + G_{M,D}D_n + G_{M,P}(Y^R + nY_n^R). \end{aligned}$$

这两个导数同时包含项目覆盖的正效应和单项目努力、绩效稀释的负效应，因而新增项目是否形成有价值的资本必须由总量变化判断。

命题 7.1. 两期模型的动态进入楔子与政策区制 固定 (K_1, M_1, s_1) ，假定第一期目标关于 n_1 严格凹、最优目标位于内部，且 $\Omega_{1,n} < 0$ 。令 n_1^m 满足 $\tilde{\Pi}_n(n_1^m) = 0$ ，令 n_1^d 满足

$\Omega_1(n_1^d) = 0$ 。则：

- (i) 若在 n_1^m 处 $V_{2,K}\tilde{T}_{K,n} + V_{2,M}\tilde{T}_{M,n} > 0$ ，则 $n_1^d > n_1^m$ ；反向不等式给出 $n_1^d < n_1^m$ 。
- (ii) 在自然进入规模 $n_1^{0,R}$ 处，若 $\Omega_1 > 0$ ，则 $n_1^d > n_1^{0,R}$ 且 $\Psi^R(n_1^d) > 0$ ，平台实施正补贴；若 $\Omega_1 = 0$ ，则 $n_1^d = n_1^{0,R}$ 且最优固定支付为零；若 $\Omega_1 < 0$ ，则 $n_1^d < n_1^{0,R}$ 且 $\Psi^R(n_1^d) < 0$ ，统一非负支付无法实施动态目标，平台需要准入控制或进入费。

证明. 在 n_1^m 处， Ω_1 的符号等于两项继续价值之和。由目标函数严格凹和 $\Omega_{1,n} < 0$ ，其符号分别意味着动态零点位于 n_1^m 右侧或左侧，得到 (i)。对 (ii)，同样比较 Ω_1 在 $n_1^{0,R}$ 处的符号即可确定 n_1^d 与自然进入规模的次序；再由 $\Psi_n^R > 0$ 及 $\Psi^R(n_1^{0,R}) = 0$ 得到实施支付的符号。□

命题7.1将“早期扩量”和“成熟期筛选”统一为同一边际条件。两阶段机器学习训练本身不能决定 Ω_1 的符号；真正发挥作用的是经营批次之间由新增项目形成的知识、数据和总绩效，以及这些收益相对于当期拥堵和实施成本的大小。

8 无限期离散时间模型与政策阶段转换

8.1 Bellman 方程

现在令 $t = 0, 1, 2, \dots$ 。每一期沿用前述合同、进入、努力、事后曝光和结算顺序，创作者项目只最大化当期收益，长期经营的平台则以 $\beta \in (0, 1)$ 折现未来利润。在技术水平 τ 固定时，平台的状态为 (K_t, M_t) 。将合同诱导的均衡结果代入状态转移，记

$$T_K(K, M, I, s) = K', \quad T_M(K, M, I, s) = M'.$$

平台的平稳 Bellman 方程为

$$V(K, M) = \max_{I \in [0, \bar{I}], s \in [0, 1]} \left\{ \Pi(K, M, I, s) + \beta V(T_K(K, M, I, s), T_M(K, M, I, s)) \right\}. \quad (36)$$

在状态和行动集合紧致、利润与转移函数连续且单期利润有界时，Bellman 算子为 β 压缩映射，故式(36)存在唯一有界连续价值函数，并存在平稳最优政策 $I^*(K, M)$ 和 $s^*(K, M)$ [25]。两期模型是该问题在终端值 $V_3 = 0$ 下的有限期版本；无限期模型则允许每一批项目持续改变未来状态。

利用式(30), 先定义一个允许固定转移支付取正或取负的辅助基准。其 Bellman 方程可以等价写成目标进入形式

$$V^\pm(K, M) = \max_{n \in [0, \bar{N}], s \in [0, 1]} \left\{ \tilde{\Pi}(K, M, n, s) + \beta V^\pm(\tilde{T}_K, \tilde{T}_M) \right\}. \quad (37)$$

这里的负支付应解释为进入费, 而不是资格审核本身给平台创造的收入。若平台只有统一非负固定支付, 则可行目标必须满足

$$0 \leq \Psi^R(n; s, K, M) \leq \bar{I},$$

等价地, $n \geq n^{0,R}(s, K, M)$ 且支付不超过上限。若平台使用零支付配额把进入压低到 $n^{0,R}$ 以下, 其当期利润应令 $I = 0$, 不能把 $-\Psi^R$ 记为转移收入。因此, 式(37)是判断何时需要补充准入工具的有符号转移支付基准, 而不是非价格准入工具与负支付在会计意义上的等价式。第9节分别求解有符号基准、仅非负支持和“非负支持加零支付配额”三种环境。

8.2 动态边际进入价值与政策阶段转换

对每个 (K, M, n) 先优化收入分成, 定义

$$\bar{Q}(n; K, M) = \max_{s \in [0, 1]} \left\{ \tilde{\Pi}(K, M, n, s) + \beta V^\pm(\tilde{T}_K, \tilde{T}_M) \right\}, \quad (38)$$

并令

$$\bar{\Omega}(n; K, M) := \bar{Q}_n(n; K, M). \quad (39)$$

由包络定理, $\bar{\Omega}$ 仍具有式(35)的三项分解, 只需将 V_2 替换为辅助基准的平稳价值函数 $V^\pm$ 。因此, 阶段转换的关键不是推荐技术本身是否提高当期匹配, 而是它是否使“再增加一个项目”的总动态价值下降。

假设 8.1 (边际进入价值的单交叉). 固定 K , $\bar{Q}$ 关于 n 严格凹, 且在相关状态区间内

$$\bar{\Omega}_n < 0, \quad \bar{\Omega}_M < 0, \quad n_M^{0,R} > 0. \quad (40)$$

此外存在 $\underline{M} < \overline{M}$ 使

$$\overline{\Omega}(n^{0,R}(K, \underline{M}); K, \underline{M}) > 0, \quad \overline{\Omega}(n^{0,R}(K, \overline{M}); K, \overline{M}) < 0. \quad (41)$$

条件 $\overline{\Omega}_n < 0$ 来自边际发现价值递减、审核成本凸性和实施支付递增。条件 $\overline{\Omega}_M < 0$ 要求推荐资本成熟时新增项目的数据价值下降得足够快。在收入分成已经最优调整后，一个便于核验的充分条件是

$$\tilde{\Pi}_{nM} + \beta \frac{\partial}{\partial M} (V_K^\pm \tilde{T}_{K,n}) + \beta \frac{\partial}{\partial M} (V_M^\pm \tilde{T}_{M,n}) < 0. \quad (42)$$

该式允许匹配改善使 $\tilde{\Pi}_{nM} > 0$ ，但要求推荐学习项的递减以及自然进入增加带来的拥堵效应占优。它比直接假定最优补贴递减更接近模型的原始经济机制。

命题 8.1. 唯一成熟阈值与三种政策区制 在假设 8.1 下，对每个固定 K 存在唯一 $M^\dagger(K) \in (\underline{M}, \overline{M})$ ，使得：

$$\begin{aligned} M < M^\dagger(K) &\implies n^d(K, M) > n^{0,R}(K, M), \quad \Psi^R(n^d) > 0, \\ M = M^\dagger(K) &\implies n^d(K, M) = n^{0,R}(K, M), \quad \Psi^R(n^d) = 0, \\ M > M^\dagger(K) &\implies n^d(K, M) < n^{0,R}(K, M), \quad \Psi^R(n^d) < 0, \end{aligned}$$

其中 n^d 为式(37)的无约束最优目标。第三种情形下，任何统一非负固定支付都不能实施 n^d 。进入费能够精确实施该有符号基准；资格审核、项目申请制、上传数量限制或题材配额也能把进入降到自然规模以下，但其最优配额须在 $I = 0$ 的利润口径下另行求解，未必数值上恰等于 n^d 。

证明. 定义自然进入处的边际价值

$$\Gamma(K, M) = \overline{\Omega}(n^{0,R}(K, M); K, M).$$

由式(40)，

$$\Gamma_M = \overline{\Omega}_M + \overline{\Omega}_n n_M^{0,R} < 0.$$

再由连续性和式(41)，存在唯一 $M^\dagger(K)$ 使 $\Gamma(K, M^\dagger) = 0$ 。由于 $\overline{Q}$ 严格凹， Γ 为正、等于零或为负分别意味着无约束目标 n^d 位于自然进入规模的右侧、等于自然进入规模或位于其左侧。最后由 $\Psi_n^R > 0$ 和 $\Psi^R(n^{0,R}) = 0$ 得到支付符号及工具约束。 $\square$

命题8.1把“选择性扶持”与简单地将补贴降为零区分开来。若式(42)不成立，例如推荐改进带来的当期匹配收益持续强于学习收益递减和拥堵成本，则 Γ 未必下降，成熟阈值也可能不存在。这一反例说明阶段转换是模型可检验的经济结论，而不是预先写入的技术叙事。

8.3 非平稳在线学习：漂移状态与马尔可夫热点

基准模型中的 M_t 是慢速积累的结构性推荐资本，表示平台的多模态表征、匹配和冷启动能力；热点状态刻画当前批次更受欢迎的题材。较高的 M_t 不能消除热点变化，一次正确判断也不会永久提高平台的通用推荐能力。本文因此采用双时间尺度：外层批次中的 (K_t, M_t) 由基准模型决定；给定结构状态 $(\bar{K}, \bar{M})$ ，在线子问题把高频曝光和反馈聚合为一次测试决策，并作为外层 Bellman 方程的条件价值。通用推荐资本的积累与当前需求信念的更新分别核算，避免同一信息收益重复进入价值函数。

本文把在线学习定义为三步经济反馈：平台行动改变当期收益与信号精度，反馈更新后验，后验再改变下一批次行动。以下给出两个替代性规格。高斯规格把热点写成连续漂移的总体匹配状态；有限状态规格刻画两类题材之间的热点切换。两者分别求解，以识别各自机制。

8.3.1 规格一：高斯漂移、后验精度与内生测试曝光

令 $\theta_t \in \mathbb{R}$ 表示第 t 批次尚未完全观察到的内容—用户匹配冲击，期初信念为

$$\theta_t | \mathcal{F}_t \sim \mathcal{N}(\mu_t, \xi_t^{-1}), \quad (43)$$

并按照

$$\theta_{t+1} = \rho_\theta \theta_t + \varepsilon_{t+1}, \quad \varepsilon_{t+1} \sim \mathcal{N}(0, \sigma_\varepsilon^2), \quad 0 < \rho_\theta < 1, \quad \sigma_\varepsilon^2 > 0 \quad (44)$$

演化。 ρ_θ 衡量热点延续性， σ_ε 衡量无法由旧数据预测的新冲击。与平稳未知参数不同，只要 $\sigma_\varepsilon > 0$ ，平台就不可能通过一次学习永久消除不确定性。

平台在观察 (μ_t, ξ_t) 后选择目标进入 n_t 、收入分成 s_t 与测试曝光强度 $a_t \in [0, 1]$ 。 a_t 汇总推荐系统在一个经营批次内分配给不确定题材、新团队和冷启动内容的额外试

验流量。为与期内均衡嵌套，令

$$g^G(\mu, a) = [1 + \chi_G \tanh(\mu)](1 - c_a a^2) > 0, \quad 0 < \chi_G < 1, \quad 0 < c_a < 1, \quad (45)$$

乘在命题6.1中的 $\eta(\bar{M})^2$ 上。第一项表示有利的预期匹配状态提高当期有效绩效，双曲正切保证无界高斯信念下的匹配乘数仍有界且为正；第二项表示试验曝光挤出部分已知高回报流量。将曝光、努力、进入支付和治理工具按照前文解析代回，得到条件期内利润 $\hat{\Pi}^G(\mu, \xi, n, s, a; \bar{K}, \bar{M})$ 。

项目反馈形成信号

$$\bar{z}_t = \theta_t + u_t, \quad u_t \sim \mathcal{N}(0, [\mathcal{T}_t^G]^{-1}), \quad (46)$$

其中基准数值规格采用

$$\mathcal{T}_t^G = \tau_G \log(1 + n_t)(d_0 + d_1 D)(1 + \gamma_G a_t) \eta(\bar{M}), \quad d_0 + d_1 = 1, \quad (47)$$

并满足 $\mathcal{T}^G(0, \cdot) = 0$ 、 $\mathcal{T}_n^G > 0$ 、 $\mathcal{T}_{nn}^G < 0$ 和 $\mathcal{T}_a^G > 0$ 。对数项表示相似项目反馈冗余； D 和 $\eta(\bar{M})$ 分别提高题材覆盖与信号处理效率。提高 n 与提高 a 都能增加信息，但前者还改变创作者进入和拥堵，后者直接牺牲部分当期匹配。

正态共轭更新给出

$$\xi_t^+ = \xi_t + \mathcal{T}_t^G, \quad (48)$$

$$\mu_t^+ = \frac{\xi_t \mu_t + \mathcal{T}_t^G \bar{z}_t}{\xi_t + \mathcal{T}_t^G}, \quad (49)$$

$$\xi_{t+1} = \left(\frac{\rho_\theta^2}{\xi_t + \mathcal{T}_t^G} + \sigma_\varepsilon^2 \right)^{-1}, \quad (50)$$

$$\mu_{t+1} = \rho_\theta \mu_t^+. \quad (51)$$

条件于当前状态和行动，

$$\mathbb{E}_t[\mu_{t+1}] = \rho_\theta \mu_t, \quad \text{Var}_t(\mu_{t+1}) = \rho_\theta^2 \left(\frac{1}{\xi_t} - \frac{1}{\xi_t + \mathcal{T}_t^G} \right). \quad (52)$$

所以更多反馈不机械提高后验均值，而是扩大平台依据不同信号调整未来政策的能力。完整历史被 (μ_t, ξ_t) 压缩，形成受行动控制的马尔可夫转移核 Q_G 。

给定 $(\bar{K}, \bar{M})$, 在线价值满足

$$W^G(\mu, \xi; \bar{K}, \bar{M}) = \max_{\substack{n \in [0, \bar{N}], s \in [0, 1] \\ a \in [0, 1]}} \left\{ \hat{\Pi}^G(\mu, \xi, n, s, a) + \beta \int W^G(\mu', \xi') Q_G(d\mu' \mid \mu, \xi, n, a) \right\}. \quad (53)$$

给定有界连续利润、紧行动集和弱连续转移核, Bellman 算子是 β 压缩映射, 故存在唯一有界连续价值函数和最优平稳马尔可夫政策。平台知道真实转移规律并进行贝叶斯过滤; Esponda and Pouzo [11] 讨论的模型误设均衡不在本文范围内。

令 $\bar{Q}^G(n; \mu, \xi)$ 表示对 (s, a) 优化后的 Bellman 目标, 并定义

$$\Omega^G(n; \mu, \xi) := \frac{\partial \bar{Q}^G(n; \mu, \xi)}{\partial n}. \quad (54)$$

若把在线子问题嵌回外层资本积累模型, 新增项目的完整边际价值为

$$\Omega^{G, \text{full}} = \underbrace{\hat{\Pi}_n^G}_{\text{当期边际利润}} + \underbrace{\beta \mathbb{E}[V_K] T_{K,n}}_{\text{创作资本价值}} + \underbrace{\beta \mathbb{E}[V_M] T_{M,n}}_{\text{通用推荐资本价值}} + \underbrace{\beta \mathcal{I}_n^G}_{\text{热点信息价值}}. \quad (55)$$

最后一项只度量对瞬时热点状态的后验适配, 不能再次包含 T_M 。当提高 n 或 a 只增加信号精度且平台可以忽略额外信号时, Blackwell 排序给出弱非负的信息价值 [6]。测试曝光的内点条件为

$$-\hat{\Pi}_a^G = \beta \frac{\partial}{\partial a} \int W^G(\mu', \xi') Q_G(d\mu' \mid \mu, \xi, n, a), \quad (56)$$

即当期匹配损失等于未来适配收益; 边界行动以相应不等式刻画。式 (56) 说明在线试验是经济选择, 不是外生指定算法。

令 $n^{0,G}(\mu, \xi)$ 为条件最优 (s, a) 下的零支付自然进入规模。为保留基准模型的政策阈值, 采用以下可核验而非自动成立的条件。

假设 8.2 (高斯在线学习下的单交叉). $\bar{Q}^G$ 关于 n 严格凹, 并在相关精度区间满足

$$\Omega_n^G < 0, \quad \Omega_\xi^G < 0, \quad n_\xi^{0,G} \geq 0. \quad (57)$$

自然进入处的 Ω^G 在某个 $\underline{\xi} < \bar{\xi}$ 的两端异号。

命题 8.2. 条件精度阈值、测试曝光与非永久成熟 在假设 8.2 下, 对每个固定 $(\bar{K}, \bar{M}, \mu)$ 存在唯一 $\xi^\dagger(\bar{K}, \bar{M}, \mu)$, 使 $\xi < \xi^\dagger$ 时目标进入高于自然进入并需正固定支持, $\xi = \xi^\dagger$ 时

固定支付为零, $\xi > \xi^\dagger$ 时目标进入低于自然进入并需选择性准入或进入费。与此同时, 式(50)满足

$$\xi_{t+1} \leq \sigma_\varepsilon^{-2},$$

因而 $\sigma_\varepsilon > 0$ 时不存在吸收性的完全信息状态; 是否长期停留在阈值某一侧取决于过程噪声、内生测试和后验均值路径。

证明. 定义自然进入处的边际价值 $\Gamma^G(\mu, \xi) = \Omega^G(n^{0,G}(\mu, \xi); \mu, \xi)$ 。由式(57), $\Gamma_\xi^G = \Omega_\xi^G + \Omega_n^G n_\xi^{0,G} < 0$; 端点异号和连续性给出唯一零点, 严格凹性再确定目标进入位于自然进入的哪一侧。精度上界直接来自式(50)的分母不小于 σ_ε^2 。□

命题8.2依赖单交叉条件。后验均值改变当期进入收益, 测试曝光又内生改变精度转移, 因此 $\Omega_\xi^G < 0$ 需要由原始函数或数值政策核验, 贝叶斯公式本身不给出这一符号。在悲观状态中, 牺牲已有匹配的机会成本较低, 平台可能更愿意试验; 测试政策由精度与当前机会成本共同决定。

8.3.2 规格二：两题材马尔可夫热点与探索—利用

高斯状态适合总体需求缓慢漂移, 但不能直接表示一个题材退潮而另一个题材变热。为此, 令真实热点 $h_t \in \{A, B\}$ 按照对称马尔可夫链变化:

$$\mathbb{P}(h_{t+1} \neq h_t) = \lambda, \quad 0 < \lambda < \frac{1}{2}. \quad (58)$$

平台的充分统计量是 $p_t = \mathbb{P}(h_t = A \mid \mathcal{F}_t)$ 。行动 $a_t \in [0, 1]$ 现在表示投向 A 类内容的曝光比例, $1 - a_t$ 投向 B 类。当前曝光与真实热点一致的期望比例为

$$m(p, a) = pa + (1 - p)(1 - a), \quad (59)$$

数值模型令 $g^H(p, a) = 1 + \chi_H[m(p, a) - 1/2]$ 乘在 $\eta(\bar{M})^2$ 上。若 $p > 1/2$, 把更多曝光投向 A 能够提高当期预期匹配; 但过度倾斜减少两类题材之间的比较反馈。

平台观察信号 $z_t \in \{A, B\}$, 其正确率为

$$\gamma(n, a; \bar{M}) = \frac{1}{2} + \bar{\gamma} \left[1 - \exp \left\{ -\tau_H n \eta(\bar{M}) (\underline{d} + (1 - \underline{d})4a(1 - a)) \right\} \right], \quad (60)$$

其中 $0 < \bar{\gamma} < 1/2$ 且 $0 < \underline{d} < 1$ 。即使全部曝光投向一类, 平台仍从该类表现获得少量

信息；平衡测试使 $4a(1-a)$ 达到 1，从而最有利于识别相对热点。更多项目和更高推荐能力提高同一曝光配置的信息量。

观察 $z = A$ 与 $z = B$ 后的过滤信念分别为

$$p_A^+ = \frac{p\gamma}{p\gamma + (1-p)(1-\gamma)}, \quad (61)$$

$$p_B^+ = \frac{p(1-\gamma)}{p(1-\gamma) + (1-p)\gamma}. \quad (62)$$

再考虑批次间热点切换，下一期信念为

$$p'_z = \lambda + (1-2\lambda)p_z^+, \quad z \in \{A, B\}. \quad (63)$$

因此即使当前后验接近 0 或 1，只要 $\lambda > 0$ ，下一期信念也会被拉回 $[\lambda, 1-\lambda]$ 。条件价值满足

$$W^H(p; \bar{K}, \bar{M}) = \max_{\substack{n \in [0, \bar{N}], s \in [0, 1] \\ a \in [0, 1]}} \left\{ \hat{\Pi}^H(p, n, s, a) + \beta \sum_{z \in \{A, B\}} \mathbb{P}(z | p, n, a) W^H(p'_z) \right\}. \quad (64)$$

该问题是一维信念状态上的部分可观察马尔可夫决策问题。与 Che and Hörner [9] 相比，本文的推荐曝光同时影响创作者进入和平台拥堵；与 Cao et al. [8] 相比，本文保留平台固定支付、收入分成和选择性准入，但不引入平台间竞争。

命题 8.3. 对称热点下的政策对称性与持续刷新 若 A 、 B 两类除标签外具有相同的创作者成本、内容质量和收益原语，则存在对称最优政策满足

$$a^*(1-p) = 1 - a^*(p), \quad n^*(1-p) = n^*(p), \quad s^*(1-p) = s^*(p).$$

若最优曝光唯一，则 $a^*(1/2) = 1/2$ 。此外， $\lambda > 0$ 时信念的支持不含吸收性的 0 或 1；政策可以随热点冲击反复进入测试区和定向利用区，而不必沿着单一成熟路径永久停止探索。

证明. 将标签 A 、 B 互换，把 p 映射为 $1-p$ 、 a 映射为 $1-a$ 。式 (59)、(60) 和转移概率率均不变，故 Bellman 算子保持这一对称性；压缩映射的唯一价值函数亦对称，最优政策集合按上述方式映射。唯一性给出 $p = 1/2$ 处 $a^* = 1/2$ 。非吸收性由式 (63) 直接得到。□

热点切换速度 λ 通过两条方向相反的渠道影响探索。更快切换使旧后验更快失效，提高信息刷新的价值；它也缩短信号改善未来决策的期限，降低信息资产的耐久性。这两条渠道产生变化环境中的不同追踪区制 [20]，其净效应在数值部分报告。高斯与热点规格共同表明：稳定环境下的精度阈值是局部政策边界；持续变化的内容市场则对应状态依赖、可逆的扶持与测试政策。

9 数值均衡求解、参数约束与稳健性

本节将期内均衡、实施支付与两类资本转移逐项代回平台问题，数值求解两期均衡和无限期平稳马尔可夫均衡。计算检验解析命题所需的凹性、实施单调性和状态边界能否在同一组透明参数下成立，并区分有符号转移支付、仅非负支持与零支付配额。所有数值结果属于部分校准和机制核验，不作为 AI 短剧补贴水平的结构估计。

9.1 公开代码的借鉴边界与数据矩

数值方法参考两类近期公开代码的组织方式。Farboodi and Veldkamp [12] 的官方复现包使用离散状态网格、插值、值函数迭代和向前模拟研究数据存量的动态价值 [13]；Yang et al. [28] 的公开教程则把有限行动网格上的 Bellman 迭代作为独立基准，并用最终 Bellman 残差核验解。本文借鉴离散网格、插值、迭代和残差核验这些通用算法结构；经济方程、参数向量和 NumPy 求解器均依据本章模型独立构造。求解器同时输出机器可读结果、迭代误差和图形。

基准参数中唯一直接来自数据的矩是 KuaiRec 公开短视频数据的类别多样性 [15, 16]。下载范围限于类别与文本表，观看、点赞和平台收益变量不进入校准。剔除未知类别后，样本包含 10,687 个视频和 40 个一级类别。令 p_j 为类别 j 的样本占比，以标准化 Shannon 熵定义内容多样性：

$$\widehat{D} = -\frac{\sum_{j=1}^J p_j \log p_j}{\log J} = 0.8745, \quad J = 40. \quad (65)$$

相应的有效类别数为 $\exp[-\sum_j p_j \log p_j] = 25.18$ 。该矩用于约束 D 的量纲；AI 短剧的合同参数和因果效应不由一般短视频类别分布识别。

9.2 部分校准、政策口径与算法

取 $\bar{N} = 4, \bar{I} = 2$ ，将状态空间设为 $K \in [0, 6], M \in [0, 10]$ 。用于计算的基础质量、固定成本上界、匹配效率和有效重叠分别为

$$A(K) = 0.72 + 0.62[1 - \exp(-0.38K)], \quad (66)$$

$$\bar{k}(K) = 0.50 + \frac{2.65}{1 + 0.20K}, \quad (67)$$

$$\eta(M) = 0.76 + 0.52[1 - \exp(-0.34M)], \quad (68)$$

$$\vartheta(M, D) = 0.28 + 0.72 \exp(-0.30M)(1 - 0.42D). \quad (69)$$

令 $r = 2, v = 0.5, c = 5, \kappa = \nu = 1.2$ ，发现价值和审核成本为 $\mathcal{B}(n) = 2.15[1 - \exp(-0.9n)]$ 、 $\omega = 1.15$ 与 $C_N(n) = 0.13n^2$ 。资本转移采用保持原始投入递增而边际递减的形式：

$$K' = 0.82K + 0.22 \log(1 + n) + 0.46 \log(1 + ne^R), \quad (70)$$

$$M' = 0.88M + 0.16 \log(1 + n) + 0.46D[1 - \exp(-0.8n)] + 0.18 \log(1 + nY^R). \quad (71)$$

折现因子取 $\beta = 0.92$ 。这一数值与近期数据资本模型采用的高折旧、高不确定性环境处于相近量级，但这里只是对内容批次快速过时风险的规范化；下文分别令 $\beta \in \{0.88, 0.96\}$ 检验敏感性。

对每个 (K, M, n, s) ，求解器先用命题6.1的闭式解计算 e^R, q^R, Y^R, S^R, g^R ，再计算 $\Psi^R = \bar{k}(K)n/\bar{N} - S^R$ 。为保持工具口径一致，实际治理环境的当期利润定义为

$$\Pi^G(K, M, n, s) = \begin{cases} n[g^R - \Psi^R] + \omega\mathcal{B}(n) - C_N(n), & 0 \leq \Psi^R \leq \bar{I}, \\ ng^R + \omega\mathcal{B}(n) - C_N(n), & \Psi^R < 0, \end{cases} \quad (72)$$

其中第二行表示平台以 $I = 0$ 并使用配额实施 $n < n^{0,R}$ ；它不包含虚构的 $-n\Psi^R$ 收入。 $\Psi^R > \bar{I}$ 的行动不可行。作为对照，计算还分别保留允许负转移的式(37)和只允许 $0 \leq \Psi^R \leq \bar{I}$ 的统一支持环境。

基准网格包含 $31 \times 41 = 1,271$ 个状态与 $49 \times 17 = 833$ 个 (n, s) 行动。两期模型先逐状态求解 V_2 ，再以双线性插值得到 $V_2(K', M')$ 并反推 V_1 。无限期模型从零价值函数出发反复应用 Bellman 算子，直到价值函数的上确界距离低于 10^{-7} ，最后重新应用一

次 Bellman 算子报告残差。附录给出两种算法的伪代码。

9.3 两期均衡：动态扩量与终端收缩

图1固定最接近 $K = 1.5$ 的网格点 $K = 1.4$ ，比较第一期和终端期政策。在 $M = 0$ 时，第一期选择 $(n_1, s_1) = (1.000, 0.3125)$ ，单位固定支付为 0.328；终端期进入为 0.917。第一期比终端期多出的进入来自式 (35) 中的两项续期资本价值，而不是另加的一条“早期扶持”规则。此时按第一期收入分成计算的自然进入仅为 0.593，所以正支付确实在外延边际上扩大进入。

当 $M = 10$ 时，第一期与终端期均选择 $n = 2.167$ ，动态楔子在行动网络上消失；相应自然进入为 2.207，最优治理采用 $I = 0$ 并留下 0.041 的配额缺口。因而，推荐资本成熟以后进入水平可以高于早期，但相对于更快上升的自然供给已经转为选择性准入。理论预测的是“目标进入与自然进入的相对次序”，并不要求成熟期项目绝对数量下降。




图 1: 两期均衡的向后归纳解

注：固定 $K = 1.4$ 。左图比较第一期、终端期与按第一期最优收入分成计算的零支付自然进入；右图分别报告正固定支付和零支付配额缺口。全部曲线由同一组期内原语和状态转移求解，不使用单独拟合的目标进入函数。

9.4 无限期均衡、工具边界与过渡路径

实际治理环境的值函数迭代在 223 次 Bellman 更新后收敛，最终残差为 8.47×10^{-8} 。有符号转移与仅非负支持两种对照分别在 224 次和 222 次更新后收敛，残差均低于 10^{-7} 。内部逻辑检查也通过：全网格最大激励强度为 $\max \zeta^R = 3.460 < c = 5$ ，创作者

努力问题保持严格凹；沿目标进入网格的最小实施支付增量为 $0.0355 > 0$ ；最优转移没有依靠把 K' 或 M' 截断在人工上界。

表1报告四个参考状态。早期状态 $(0.5, 0.5)$ 下，平台选择 $n = 1.500$ 并支付 0.812 ；随着两类资本积累，固定支付逐步降至接近零。在 $(3.5, 8.5)$ ，最优进入 3.042 低于自然进入 3.088 ，平台以零支付配额留下 0.046 的缺口。收入分成没有机械地随成熟度单调变化，因为它同时协调创作者努力与平台事后曝光；政策阶段的识别来自固定支付或配额，而不是强迫 s 承担所有调整。

表 1: 无限期治理均衡的参考状态

K	M	n^G	s^G	$n^{0,R}$	固定支付	配额缺口
0.5	0.5	1.500	0.3750	0.572	0.812	0.000
1.5	3.0	1.833	0.4375	1.588	0.233	0.000
2.5	6.0	2.458	0.3750	2.422	0.033	0.000
3.5	8.5	3.042	0.3750	3.088	0.000	0.046

图2把三种工具环境放在一起。有符号转移基准在 $\Psi^R < 0$ 时可以收取进入费；仅非负支持的政策不能把进入降到自然规模以下；“非负支持加配额”则在不计算负转移收入的情况下实施选择性准入。因此，三条曲线的差异不是数值误差，而是工具集合不同所产生的经济差异。




图 2: 无限期平稳政策与工具集合

注：固定 $K = 1.4$ 。有符号基准允许进入费；support only 只允许统一非负固定支付；support + quota 在 $\Psi^R < 0$ 时令 $I = 0$ 并选择配额。右图报告实际治理环境的工具强度。

从 $(K_0, M_0) = (0.2, 0.2)$ 出发向前模拟 60 个经营批次，固定支付由 0.870 持续下降，在零附近的离散行动之间短暂切换；第 31 期以后不再回到正支付，并持续使用小幅配额。第 60 期达到 $(K, M) = (3.974, 8.396)$ ，进入约为 2.949。图 3 由同一平稳政策函数内生生成，未预先指定政策切换日期。




图 3: 无限期均衡的内生状态与政策过渡

注：左图为两类资本，右图为进入、固定支付和配额缺口。竖虚线表示模拟路径上正固定支付最后一次出现之后的首个批次；阈值附近的微小往返来自离散行动网格。

9.5 敏感性、网格误差与可复现边界

表 2 改变折现、内容多样性、资本折旧和网格密度。所有情形均保留“早期正支付、成熟状态存在配额缺口”的定性结论。较高 β 提高早期进入和支持，因为平台更重视资本积累；更快折旧则降低长期状态。切换批次不必关于单个参数单调，因为 K_t 和 M_t 同时改变自然进入、质量与政策函数。粗网格把永久切换推迟 5 个批次，但参考状态的进入和支付差异较小，说明核心结论不依赖某一个网格点。

表 2: 参数与网格敏感性

情形	β	D	初始进入	初始支付	成熟配额缺口	永久切换批次
基准细网格	0.92	0.875	1.500	0.812	0.046	31
粗网格	0.92	0.875	1.533	0.821	0.048	36
低折现	0.88	0.875	1.363	0.678	0.048	23
高折现	0.96	0.875	1.741	0.991	0.048	34
低多样性	0.92	0.775	1.474	0.777	0.040	27
高多样性	0.92	0.925	1.533	0.817	0.052	31
快折旧 $(\delta_K, \delta_M) = (0.24, 0.18)$	0.92	0.875	1.363	0.694	0.048	26

注：初始参考状态为 $(K, M) = (0.5, 0.5)$ ，成熟参考状态为 $(3.5, 8.5)$ 。粗网格为 21×29 个状态、 37×13 个行动；其余敏感性也在粗网格求解。

9.6 在线学习均衡：条件求解、政策函数与随机路径

在线扩展用双时间尺度分解 (K, M, μ, ξ) 或 (K, M, p) 的高维联合状态。基准模型先决定慢速结构状态 $(\bar{K}, \bar{M})$ ；在线子问题再在给定结构状态下求解进入、分成与测试曝光的无限期信念状态均衡。这个分层求解保留热点反馈的动态价值，并将同一反馈分别限定在 M' 或热点后验中，避免同时更新 M 而重复计量。高斯规格取 $(\bar{K}, \bar{M}) = (1.5, 3.0)$ 、 $\rho_\theta = 0.88$ 、 $\sigma_\varepsilon = 0.16$ 、 $\chi_G = 0.55$ 、 $c_a = 0.06$ 、 $\tau_G = 1.35$ 、 $\gamma_G = 2.50$ 及 $(d_0, d_1) = (0.55, 0.45)$ 。状态网格为 25×17 个 (μ, ξ) 点，行动网格为 $17 \times 9 \times 9$ 个 (n, s, a) 点；后验均值积分使用五节点 Gauss-Hermite 求积和双线性插值。基准解在 211 次更新后收敛，Bellman 残差为 8.54×10^{-8} ，且 $\max \zeta^R = 3.355 < c = 5$ 。

图4显示，测试曝光由后验均值与精度共同决定。在悲观且低精度的状态 $(\mu, \xi) = (-0.3, 3)$ ，平台选择 $(n, a, s) = (1.25, 0.50, 0.375)$ ，单位固定支持为 0.010；当 $\mu = 0$ 且 $\xi = 3$ 时，平台选择 $(1.50, 0, 0.375)$ 。直觉是，悲观状态中把流量从当前最优匹配移向测试的机会成本较低，而中性状态已有较高当期匹配收益。固定 $\mu = -0.3$ 时，测试曝光随精度上升，从 $\xi = 3$ 时的 0.50 降至 $\xi \approx 14$ 附近的 0.125，在更高精度处降为零。数值结果由此识别出“均值与精度共同决定的测试区”。以固定随机种子模拟 90 个批次，平均测试曝光为 0.057、平均进入为 1.419，后验均值对真实状态的均方根误差为 0.216；路径没有触及 μ 或 ξ 网格边界。




图 4: 高斯漂移状态下的在线学习均衡

注：上排为条件政策函数，下排为一条 90 批次随机路径。测试曝光 a 牺牲部分当期匹配，但通过(47)提高下一期后验适配；进入和固定支持由同一组期内创作者均衡原语反推。

马尔可夫热点规格取 $\lambda = 0.08$ 、 $\chi_H = 0.35$ 、 $\bar{\gamma} = 0.45$ 、 $\tau_H = 0.72$ 与 $\underline{d} = 0.15$ ，在 81 个信念点和 $17 \times 9 \times 21$ 个 (n, s, a) 行动上求解。早期结构状态 $(K, M) = (0.5, 0.5)$ 与成熟状态 $(3.5, 8.5)$ 的 Bellman 残差分别为 8.89×10^{-9} 和 9.13×10^{-9} 。在 $p = 0.5$ 时，对称性使 $a = 0.5$ ，比较测试强度 $4a(1-a)$ 等于 1；早期进入为 1 并支付 0.388，成熟期进入为 3、自然进入为 3.088，因而使用零支付配额留下 0.088 的缺口。在 $p = 0.1$ 或 0.9 时，成熟平台将曝光全部投向更可能的热点，测试强度为零，最优进入 2.5 低于自然进入 3.466。这里的“成熟”只改变慢速结构资本；热点信念仍会因 $\lambda > 0$ 反复回到比较测试区。




图 5: 两题材马尔可夫热点下的探索—利用均衡

注: a 为 A 类曝光份额, $4a(1-a)$ 为两类之间的比较测试强度。上排比较政策函数, 下排为早期结构状态下 100 批次随机路径; 进入在右下图除以 4 以便与曝光份额同轴展示。

表3进一步区分信息持久性与信息质量。高斯模型中, 在诊断状态 $(\mu, \xi) = (-0.3, 3)$, 降低持久性把测试曝光从 0.50 降至 0.125, 提高测试成本则降至 0.375; 在同一均值、较高精度 $\xi \approx 14$ 时, 各情形测试均为零。热点模型在 $p = 0.65$ 处把 λ 从 0.02 提高至 0.08, 比较测试强度由 0.938 降至 0.750; 当 $\lambda = 0.18$ 或信号上限降至 0.30 时, 该状态转为完全利用。该组结果说明, 刷新需求并不自动压倒信息寿命缩短: 越快变化或越弱反馈都可能降低一次测试的未来价值。基准热点随机路径的平均测试强度为 0.389, 平台信念对真实热点的分类准确率为 0.760。这些数值用于机制校准, 不识别现实推荐算法的权重。

表 3: 在线学习政策的参数敏感性

规格	情形	诊断状态	测试政策	Bellman 残差
高斯	基准	$(\mu, \xi) = (-0.3, 3)$	$a = 0.500$	2.75×10^{-7}
高斯	低持久性 $\rho_\theta = 0.70$	同上	$a = 0.125$	2.75×10^{-7}
高斯	高测试成本 $c_a = 0.12$	同上	$a = 0.375$	2.75×10^{-7}
热点	慢切换 $\lambda = 0.02$	$p = 0.65$	$4a(1 - a) = 0.938$	2.71×10^{-8}
热点	基准 $\lambda = 0.08$	同上	$4a(1 - a) = 0.750$	2.64×10^{-8}
热点	快切换 $\lambda = 0.18$	同上	$4a(1 - a) = 0$	2.60×10^{-8}
热点	弱反馈 $\bar{\gamma} = 0.30$	同上	$4a(1 - a) = 0$	2.61×10^{-8}

注：高斯敏感性使用 19×13 状态网格和与基准相同的 $17 \times 9 \times 9$ 行动网格，停止容差为 3×10^{-7} ；热点敏感性使用 61 个信念点和较粗行动网格。高斯各情形在 $(\mu, \xi) = (-0.3, 14)$ 处均选择 $a = 0$ 。

基础动态均衡由 `scripts/solve_dynamic_equilibria.py` 生成，两种在线学习均衡由 `scripts/solve_online_learning_extensions.py` 生成；参数、残差、参考状态和敏感性结果保存在 `output/computation/`，公开代码与数据的原始压缩包、校验值和使用边界记录在 `literature_recent_discrete_models/replication_code_sources/README.md`。这些文件使数值结论可以复算，同时保留“算法借鉴”与“模型原创”的边界。

10 可检验预测与经验设计

10.1 理论预测

模型产生六组可以区分的经验预测。

第一，普惠固定支付或收入保底上升会扩大项目进入，但在推荐资本和内容构成不变时，会降低单项目平均曝光、人工质量努力和变量收益。该稀释效应应当在题材同质度较高、即 $\vartheta(M, D)$ 较大的类别中更强；在内容差异较大的类别中，项目数增加造成的有效拥堵较弱。

第二，当 $v < r$ 时，收入分成对进入和质量努力呈倒 U 形，其转折点为 $s^\dagger = (v + r)/(2r)$ 。平台非分账价值 v 越高，转折点越靠右；若 $v \geq r$ ，在基准可行区间内收入分成对进入和努力不再出现下降段。

第三，推荐技术升级同时提高 $\eta(M)$ 并降低 $\vartheta(M, D)$ 时，应当提高新发布和长尾项目的冷启动曝光、单项目有效绩效以及零补贴进入规模。其影响不仅体现为总曝光增加，还应体现为相似项目之间的曝光挤出减弱。Zhou et al. [29]报告的生产部署结果

与这一机制相容，但并不构成对本文结构参数或因果效应的直接估计。

第四，若式(40)与式(41)成立，推荐资本跨过 $M^\dagger$ 以后，普惠补贴降至零而资格审核、项目申请制和定向扶持的重要性上升。若观察到技术升级以后普惠补贴反而扩大，则表明匹配改善带来的当期边际收益可能超过数据学习收益递减和拥堵成本，式(42)不成立。

第五，在高斯在线学习扩展中，新增项目与测试曝光都提高信号精度，但二者的政策含义不同。若用冷启动项目量衡量 n_t 、用探索流量占比衡量 a_t 、用样本外预测误差的倒数代理 ξ_t ，式(47)预言 n_t 、 a_t 与下一批次预测改善正相关，且同一项目量下题材多样性 D_t 越高，信息增量越大。不过最优 a_t 还取决于后验均值 μ_t 所决定的机会成本，因而低精度本身不足以推出高测试；经验上应同时控制平台对当前热点收益的预测，而不能只回归不确定性。

第六，在马尔可夫热点扩展中，观察到题材切换以后，旧信念先失准，平台随后在两类题材之间增加比较曝光并重新定向。该调整可以反复发生，而不是只在产业早期出现一次。信号更准确、热点持续时间更长时，一次比较测试更能改善未来匹配；但切换概率 λ 对测试强度没有一般的单调符号。因而可检验对象不是“热点越快必然越探索”，而是测试政策如何同时响应预测误差、估计的热点持续期以及反馈质量。

10.2 变量构造与识别思路

经验研究可以使用“项目—平台—批次”面板。核心结果变量包括批次进入项目数、单项目测试曝光、后续推荐曝光、有效观看或付费转化、人工精修投入以及项目退出。固定支付 I_t 可以由制作补贴、保底金额或平台投资计划构造；收入分成 s_t 由合同条款构造；平台推荐资本 M_t 可由明确的算法版本更新、冷启动识别准确率或上线前后的匹配指标代理。在高斯扩展中， μ_t 可由平台在批次开始时对题材或人群转化率的预测构造， ξ_t 可由预测区间宽度、后验方差或滚动样本外误差的倒数代理；二者应当分别测量“平台预计什么会成功”和“平台对此有多确定”，不能合并为同一个准确率指标。测试曝光 a_t 应使用平台明确标记的探索桶、随机流量或冷启动保留流量构造，不能把事后获得大量推荐的成功内容误记为事前探索。马尔可夫扩展还需要先按题材份额构造热点指标 h_t ，用相邻批次热点变化估计 λ ，并用平台期初预测构造 p_t ；若只有最终播放量而没有期初预测或曝光规则，无法把探索选择与需求冲击区分开。

内容多样性可以利用公开多模态表征模型生成项目向量。令标准化后的项目表示

为 z_i ，则批次多样性的一种可操作定义是

$$D_t = 1 - \frac{2}{n_t(n_t - 1)} \sum_{i < j} \frac{z_i^\top z_j}{\|z_i\| \|z_j\|}. \quad (73)$$

WeMM-Embedding 可以用于生成文本、封面和视频的统一表示 [29]，但经验部分应报告替代模型、不同向量维度和不同视频抽帧方式下的稳健性，避免把单一表征模型的测量误差误认为经济效应。

若存在清晰的平台补贴调整或推荐系统升级时间，可以估计项目层面的事件研究：

$$y_{ipt} = \alpha_i + \lambda_t + \sum_{\ell \neq -1} \beta_\ell \mathbf{1}(t - T_p = \ell) + \gamma X_{ipt} + \varepsilon_{ipt}, \quad (74)$$

其中 T_p 为平台 p 的政策或技术变更时点， y_{ipt} 依次取进入、曝光或绩效指标。为检验语义拥堵机制，可以加入政策变量与 D_t 或平均相似度的交互项。由于补贴和算法升级通常会响应既有增长趋势、内容质量和监管环境，简单的前后比较不能解释为因果效应；至少需要检验事件前趋势，并利用分批上线、资格边界或其他外生实施差异加强识别。

11 结论与适用边界

生成式人工智能对内容市场的影响超出一次生产率冲击。它降低部分创作任务的成本，扩大可进入市场的项目集合，也把平台的核心约束推向内容发现、注意力配置、审核和跨期学习。本文以 AI 短剧为主要应用，构造生成式内容平台的动态模型，把固定支付、收入分成、人工质量努力和事后推荐放入同一时序。新增项目的动态边际价值贯穿全文：项目带来当期经营与爆款发现价值，积累创作资本和推荐资本，同时加剧注意力拥堵、筛选成本和激励稀释。

模型的核心解释是“稀缺性的迁移”。推荐资本较低时，平台尚不了解新的题材、团队和用户群，扩大项目试验具有较高的数据与发现价值，普惠式支持因而可能最优。随着自然进入增加和推荐资本成熟，新增相似项目提供的学习价值下降，平台的稀缺资源转为测试流量、审核能力和高质量人工精修。此时，将补贴简单降至零仍可能带来过多自然进入，平台需要通过资格审核、项目申请制或定向扶持实施更低的目标规模。当内容供给变得廉价，平台的识别和治理能力由此成为更稀缺的投入，中介作用随之转向筛选与匹配。

两种在线学习扩展为这一机制补充了信息基础。高斯规格用后验均值 μ_t 与精度 ξ_t 概括持续漂移的匹配状态，平台在进入规模以外内生选择测试曝光。当信息边际价值随既有精度递减且单交叉成立时，确定性成熟阈值推广为条件阈值 $\xi^\dagger(\bar{K}, \bar{M}, \mu)$ ；过程噪声又使平台无法永久达到完全信息。马尔可夫规格则把热点写成两类题材之间的随机切换，曝光份额既决定当前命中概率，也决定相对题材信号的质量。新冲击使信念和政策发生可逆调整，结构资本成熟后仍会出现探索。两个规格均把新增项目与测试曝光刻画为可能替代、也可能互补的信息生产工具。更快热点切换同时提高刷新需要并缩短信号寿命，其净效应由原语和数据判定。贝叶斯更新与马尔可夫转移由此产生可检验的状态演化和政策函数。

上述结论是利润最大化平台的正向预测，不构成选择性准入提高社会福利的规范判断。平台治理研究表明，平台的收费方式和竞争激励可能使准入、推荐或质量标准相对社会最优过松或过严 [26]。本文尚未显式写入用户剩余、创作者长期职业选择、平台间竞争和内容表达多样性的独立社会价值，因此 $M > M^\dagger$ 只意味着统一非负支付无法实施平台自己的目标进入规模。若要评价监管政策，还需要把平台目标与社会规划者目标分开，并纳入错误淘汰、创新多样性和创作者剩余。

模型边界集中在四处。第一，单平台局部均衡将用户规模和潜在项目池视为给定，每期创作者主要进行当期优化；创作者多归属、基础模型定价、版权责任、平台自制内容和用户对 AI 标签的偏好尚未进入模型。第二，在线数值模型条件化处理慢速结构状态，高斯规格使用有限数值网格，热点规格只保留两个对称题材。第三，数值结果是一组经过数据矩约束的部分校准均衡，不是结构估计；短视频类别数据只约束多样性，不能识别现实 AI 短剧合同、推荐算法权重或福利参数。第四，模型适用于平台集中分发、依赖推荐冷启动、存在标准化扶持或分成，并能从项目反馈中学习的生成式内容市场。AI 短剧满足这些制度条件，是优先的经验检验场景；向其他内容类别外推需要重新核验这些条件。

12 附录

A 符号表

- K_t : 创作资本； M_t : 平台推荐资本； τ : 外生生成式人工智能技术水平。
- I_t : 单位项目固定支付； s_t : 创作者收入分成； $\Lambda(s_t) = v + (1 - s_t)r$: 平台单位绩

效剩余价值。

- n_t : 进入项目规模; $k_{i,t}$: 项目固定制作成本; F_k : 固定成本分布。
- $e_{i,t}$: 人工质量努力; $q_{i,t}$: 内容质量; $x_{i,t}$: 推荐曝光; $Y_{i,t}$: 有效绩效。
- $\eta(M_t)$: 多模态识别与用户匹配效率; D_t : 内容多样性; $\vartheta(M_t, D_t)$: 有效注意力重叠。
- $\mathcal{B}(n_t)$: 当期爆款发现价值; $C_N(n_t)$: 筛选、版权核验与审核成本。
- G_K, G_M : 创作资本和推荐资本积累函数; δ_K, δ_M : 相应折旧率; β : 平台折现因子。
- Ψ^R : 实施目标进入规模所需的固定支付; $n^{0,R}$: 零补贴自然进入规模; n^d : 有符号转移支付辅助基准中的动态目标进入规模。
- Ω_1 与 $\bar{\Omega}$: 两期和无限期模型中的动态边际进入价值; $M^\dagger$: 普惠支持转向选择性准入的推荐资本阈值。
- $V_t(K_t, M_t)$ 与 $V(K, M)$: 有限期和无限期平台价值函数。
- θ_t : 高斯扩展中的潜在内容—用户匹配状态; μ_t 与 ξ_t : 其后验均值与后验精度。
- a_t : 高斯扩展中的测试曝光强度, 或热点扩展中的 A 类曝光份额; 其含义由规格区分。
- $\mathcal{T}_t^G$ 与 Q_G : 高斯扩展的反馈精度与受控后验转移核; $W^G(\mu, \xi; \bar{K}, \bar{M})$: 条件在线价值。
- Ω^G 与 $\xi^\dagger(\bar{K}, \bar{M}, \mu)$: 高斯动态边际进入价值与条件后验精度阈值。
- $h_t \in \{A, B\}$: 真实热点; $p_t = \mathbb{P}(h_t = A \mid \mathcal{F}_t)$: 热点信念; λ : 热点切换概率。
- $\gamma(n, a; \bar{M})$: 二元热点信号正确率; $W^H(p; \bar{K}, \bar{M})$: 马尔可夫热点条件价值。

B 离散时期的解释

本文的一期对应一个合同和内容批次完成全部经营环节的时间窗口, 经验应用可以按月、季度或一次平台扶持计划的结算周期确定。期内推荐可以包含多轮实时排序;

模型在批次结束时把这些高频决策聚合为曝光、绩效与数据反馈。离散时间由此表示经营活动的经济聚合。WeMM-Embedding 的两阶段训练属于机器学习流程，与本文的两个经济时期相互独立。

C 数值均衡算法与复现检查

算法1先在终端期逐状态求最大值，再用双线性插值评价第一期行动产生的非网格下一期状态。创作者侧变量不进入额外行动维度，而是在每个候选 (n, s) 下由命题6.1解析代回。

Algorithm 1 两期均衡的向后归纳

Require: 状态网格 $\mathcal{G}_K \times \mathcal{G}_M$ ，行动网格 $\mathcal{G}_n \times \mathcal{G}_s$

- 1: **for** 每个状态 (K, M) 和行动 (n, s) **do**
 - 2: 计算 $e^R, q^R, Y^R, S^R, g^R, \Psi^R$ 和治理利润 Π^G
 - 3: 计算下一状态 (K', M') 及其插值索引与权重
 - 4: **end for**
 - 5: **for** 每个终端状态 (K, M) **do**
 - 6: $V_2(K, M) \leftarrow \max_{n,s} \Pi^G(K, M, n, s)$ 并保存最优行动
 - 7: **end for**
 - 8: **for** 每个第一期状态 (K, M) **do**
 - 9: 以双线性插值得到 $\hat{V}_2(K', M')$
 - 10: $V_1(K, M) \leftarrow \max_{n,s} \{\Pi^G + \beta \hat{V}_2(K', M')\}$ 并保存最优行动
 - 11: **end for**
-

算法2对无限期 Bellman 算子进行值函数迭代。收敛后再进行一次完整 Bellman 更新，以该次更新与已收敛价值函数的上确界距离作为残差。

Algorithm 2 无限期平稳马尔可夫均衡的值函数迭代**Require:** 预计算的 $\Pi^G(K, M, n, s)$ 、下一状态插值索引与权重；容差 $\varepsilon = 10^{-7}$

- 1: 初始化 $V^{(0)}(K, M) = 0$, 令 $j = 0$
- 2: **repeat**
- 3: **for** 每个状态 (K, M) **do**
- 4: $V^{(j+1)}(K, M) \leftarrow \max_{n,s} \{\Pi^G + \beta \hat{V}^{(j)}(K', M')\}$
- 5: 保存实现最大值的 $(n^{(j+1)}, s^{(j+1)})$
- 6: **end for**
- 7: $d_j \leftarrow \|V^{(j+1)} - V^{(j)}\|_\infty$, $j \leftarrow j + 1$
- 8: **until** $d_{j-1} < \varepsilon$
- 9: 再应用一次 Bellman 算子, 报告残差 $\|\mathcal{T}V^{(j)} - V^{(j)}\|_\infty$
- 10: 从给定 (K_0, M_0) 按平稳政策和式(71)向前模拟

算法3在给定 $(\bar{K}, \bar{M})$ 时求解高斯信念状态。后验精度由行动确定, 下一期后验均值为条件正态变量; 五节点 Gauss-Hermite 求积近似这一期望, 二维插值评价非网格 (μ', ξ') 。匹配乘数中的 $\tanh(\mu)$ 保证无界理论状态下收益有界; 数值网格只近似高概率区域, 随机路径的边界命中率另行报告。

Algorithm 3 高斯漂移状态的信念空间值函数迭代**Require:** 网格 $\mathcal{G}_\mu \times \mathcal{G}_\xi$ 与 $\mathcal{G}_n \times \mathcal{G}_s \times \mathcal{G}_a$; 求积节点 $(u_j, w_j)_{j=1}^5$

- 1: **for** 每个状态 (μ, ξ) 和行动 (n, s, a) **do**
- 2: 解析计算期内均衡、实施支付 Ψ^R 、利润 $\hat{\Pi}^G$ 和 $\mathcal{T}^G$
- 3: 由式(50)计算 ξ' , 由式(52)计算后验均值标准差 $\sigma_{\mu'}$
- 4: **end for**
- 5: 初始化 $W^{G,(0)} = 0$
- 6: **repeat**
- 7: 对每个行动计算 $\hat{\Pi}^G + \beta \sum_{j=1}^5 w_j \hat{W}^{G,(r)}(\rho_\theta \mu + \sqrt{2} \sigma_{\mu'} u_j, \xi')$
- 8: 对 (n, s, a) 取最大值得到 $W^{G,(r+1)}$ 并保存政策
- 9: **until** $\|W^{G,(r+1)} - W^{G,(r)}\|_\infty < 10^{-7}$
- 10: 再应用一次 Bellman 算子报告残差, 并按真实状态和信号方程向前模拟

算法4利用二元信号的有限支持直接求和，不需要数值积分。对称环境下，求解器还逐点核验 $a^*(1-p) = 1 - a^*(p)$ 与进入政策的镜像对称性。

Algorithm 4 两题材马尔可夫热点的信念空间值函数迭代

Require: 信念网格 $\mathcal{G}_p$, 行动网格 $\mathcal{G}_n \times \mathcal{G}_s \times \mathcal{G}_a$, 切换概率 λ

- 1: **for** 每个 p 与 (n, s, a) **do**
 - 2: 计算期内利润、信号正确率 $\gamma(n, a; \bar{M})$ 及 $\mathbb{P}(z = A)$ 、 $\mathbb{P}(z = B)$
 - 3: 按式(62)和式(63)计算 p'_A 与 p'_B
 - 4: **end for**
 - 5: 初始化 $W^{H,(0)} = 0$
 - 6: **repeat**
 - 7: 对每个行动计算 $\hat{\Pi}^H + \beta[\mathbb{P}(z = A)\widehat{W}^{H,(r)}(p'_A) + \mathbb{P}(z = B)\widehat{W}^{H,(r)}(p'_B)]$
 - 8: 对 (n, s, a) 取最大值得到 $W^{H,(r+1)}$ 并保存政策
 - 9: **until** $\|W^{H,(r+1)} - W^{H,(r)}\|_\infty < 10^{-8}$
 - 10: 重新计算 Bellman 残差，并按隐藏热点切换和二元信号向前模拟
-

基准求解的三项必要内部检查为： $\max \zeta^R < c$ 、沿 n 网格的 $\Delta \Psi^R > 0$ 以及转移不撞击状态空间上界。它们分别排除创作者努力非凹、目标进入表示失去单调性和数值结果由边界截断制造三类逻辑错误。敏感性分析另外改变状态与行动网格，核验政策阶段转换不是某个离散点的产物。在线学习还检查高斯随机路径不命中状态网格边界、两种规格的 $\max \zeta^R < c$ 、热点政策对称性与最终 Bellman 残差；只有这些检查同时通过，政策函数才写入正文表图。

参考文献

- [1] Acemoglu, D. (2025). The simple macroeconomics of AI. *Economic Policy*, 40(121):13–58.
- [2] Anderson, S. P. and Peitz, M. (2023). Ad clutter, time use, and media diversity. *American Economic Journal: Microeconomics*, 15(2):227–270.
- [3] Bergemann, D., Bonatti, A., and Gan, T. (2022). The economics of social data. *The RAND Journal of Economics*, 53(2):263–296.

- [4] Besbes, O., Gur, Y., and Zeevi, A. (2015). Non-stationary stochastic optimization. *Operations Research*, 63(5):1227–1244.
- [5] Bhargava, H. K. (2022). The creator economy: Managing ecosystem supply, revenue sharing, and platform design. *Management Science*, 68(7):5233–5251.
- [6] Blackwell, D. (1953). Equivalent comparisons of experiments. *The Annals of Mathematical Statistics*, 24(2):265–272.
- [7] Brynjolfsson, E., Li, D., and Raymond, L. R. (2025). Generative AI at work. *The Quarterly Journal of Economics*, 140(2):889–942.
- [8] Cao, H. H., Ma, L., Ning, Z. E., and Sun, B. (2024). How does competition affect exploration vs. exploitation? a tale of two recommendation algorithms. *Management Science*, 70(2):1029–1051.
- [9] Che, Y.-K. and Hörner, J. (2018). Recommender systems as mechanisms for social learning. *The Quarterly Journal of Economics*, 133(2):871–925.
- [10] Doshi, A. R. and Hauser, O. P. (2024). Generative AI enhances individual creativity but reduces the collective diversity of novel content. *Science Advances*, 10(28):eadn5290.
- [11] Esponda, I. and Pouzo, D. (2021). Equilibrium in misspecified markov decision processes. *Theoretical Economics*, 16(2):717–757.
- [12] Farboodi, M. and Veldkamp, L. (2022). A model of the data economy. NBER Working Paper 28427, National Bureau of Economic Research. Revised June 2022.
- [13] Farboodi, M. and Veldkamp, L. (2026). Replication package for: A model of the data economy.
- [14] Fleder, D. and Hosanagar, K. (2009). Blockbuster culture’s next rise or fall: The impact of recommender systems on sales diversity. *Management Science*, 55(5):697–712.
- [15] Gao, C. (2026). KuaiRec dataset with raw features.

- [16] Gao, C., Li, S., Lei, W., Chen, J., Li, B., Jiang, P., He, X., Mao, J., and Chua, T.-S. (2022). KuaiRec: A fully-observed dataset and insights for evaluating recommender systems. In *Proceedings of the 31st ACM International Conference on Information and Knowledge Management*, pages 540–550.
- [17] Hagiu, A. and Wright, J. (2015). Multi-sided platforms. *International Journal of Industrial Organization*, 43:162–174.
- [18] Hagiu, A. and Wright, J. (2023). Data-enabled learning, network effects, and competitive advantage. *The RAND Journal of Economics*, 54(4):638–667.
- [19] Holmström, B. (1979). Moral hazard and observability. *The Bell Journal of Economics*, 10(1):74–91.
- [20] Keller, G. and Rady, S. (1999). Optimal experimentation in a changing environment. *The Review of Economic Studies*, 66(3):475–507.
- [21] Laiho, T., Murto, P., and Salmi, J. (2025). Gradual learning from incremental actions. *Theoretical Economics*, 20(1):93–130.
- [22] Li, L., Chu, W., Langford, J., and Schapire, R. E. (2010). A contextual-bandit approach to personalized news article recommendation. In *Proceedings of the 19th International Conference on World Wide Web*, pages 661–670. ACM.
- [23] Qian, K. and Jain, S. (2024). Digital content creation: An analysis of the impact of recommendation systems. *Management Science*, 70(12):8668–8684.
- [24] Rochet, J.-C. and Tirole, J. (2003). Platform competition in two-sided markets. *Journal of the European Economic Association*, 1(4):990–1029.
- [25] Stokey, N. L., Lucas, R. E., and Prescott, E. C. (1989). *Recursive Methods in Economic Dynamics*. Harvard University Press, Cambridge, MA.
- [26] Teh, T.-H. (2022). Platform governance. *American Economic Journal: Microeconomics*, 14(3):213–254.
- [27] Xu, W. and Yang, S. (2026). Dynamic pricing with recommendation and consumer feedback. *The RAND Journal of Economics*, 57(2):349–367.

- [28] Yang, Y., Wang, C., Schaab, A., and Moll, B. (2025). Structural reinforcement learning for heterogeneous agent macroeconomics. Companion tutorial code available at <https://github.com/StructuralRL/SRL>.
- [29] Zhou, J., Mei, K., Li, L., Wang, T., Rao, F., and Lyu, J. (2026). WeMM-Embedding: WeChat multi-modal embedding technical report. *arXiv preprint arXiv:2608.24053*. Available at <https://arxiv.org/abs/2608.24053>.